

# 机器学习中的优化算法

Lecture07: 复合优化算法–Nesterov加速算法

张立平

清华大学数学科学系

办公室：理科楼#A302, Tel: 62798531

E-mail: [lipingzhang@tsinghua.edu.cn](mailto:lipingzhang@tsinghua.edu.cn)

## Contents and Acknowledgement

- 教材：最优化：建模、算法与理论

<http://bicmr.pku.edu.cn/wenzw/bigdata2021.html>

- 致谢：北京大学文再文教授

## Outline of Lecture07

- FISTA
- 其他加速算法
- 应用: LASSO问题
- 收敛性分析

## Nesterov加速算法简史

### ► 复合优化问题

$$\min_{x \in \mathbb{R}^n} \psi(x) = f(x) + h(x) \quad (1)$$

的近似点梯度法

$$x^{k+1} = \text{prox}_{t_k h}(x^k - t_k \nabla f(x^k))$$

在基本假设下, 步长取常数 $t_k = 1/L$ 时, 收敛速度为 $\mathcal{O}(1/k)$ .

### ► Nesterov加速算法:

- 一个自然的问题是如果仅用梯度信息, 我们能不能取得更快的收敛速度.
- Nesterov分别在1983年、1988年和2005年提出了三种改进的一阶算法, 收敛速度能达到 $\mathcal{O}(1/k^2)$ . 实际上, 这三种算法都可以应用到近似点梯度法上.
- 在Nesterov加速算法刚提出的时候, 由于牛顿算法有更快的收敛速度, Nesterov加速算法在当时并没有引起太多的关注. 但近年来, 随着数据量

的增大, 牛顿型方法由于其过大的计算复杂度, 不便于有效地应用到实际中, Nesterov加速算法作为一种快速的一阶算法重新被挖掘出来并迅速流行起来.

- Beck和Teboulle就在2008年给出了Nesterov在1983年提出的算法的近似点梯度法版本——**FISTA**.
- **FISTA算法**由两步组成: 第一步沿着前两步的计算方向计算一个新点, 第二步在该新点处做一步近似点梯度迭代.




Figure 1: FISTA算法

- FISTA的迭代格式:

$$\begin{aligned} y^k &= x^{k-1} + \frac{k-2}{k+1}(x^{k-1} - x^{k-2}), \\ x^k &= \text{prox}_{t_k h}(y^k - t_k \nabla f(y^k)), \quad t_k \in \left(0, \frac{1}{L}\right]. \end{aligned} \tag{2}$$

- FISTA的等价变形:

$$\begin{aligned} y^k &= (1 - \gamma_k)x^{k-1} + \gamma_k v^{k-1}, \\ x^k &= \text{prox}_{t_k h}(y^k - t_k \nabla f(y^k)), \\ v^k &= x^{k-1} + \frac{1}{\gamma_k}(x^k - x^{k-1}). \end{aligned} \tag{3}$$

- 在(3)中, 当 $\gamma_k = \frac{2}{k+1}$ , 且取固定步长时, 算法(2)与(3)是等价的.
- 当 $\gamma_k$ 采用别的取法时, 算法(3)将给出另一个版本的加速算法.
- 也就是说, 算法(2)中 $\frac{k-2}{k+1}$ 可以取其他值.

## FISTA的收敛条件

► 如何选取步长 $t_k$ 和 $\gamma_k$ 决定了算法(3)的收敛速度. 算法(3)以 $\mathcal{O}(1/k^2)$ 的速度收敛的条件:

$$f(x^k) \leq f(y^k) + \langle \nabla f(y^k), x^k - y^k \rangle + \frac{1}{2t_k} \|x^k - y^k\|_2^2, \quad (4)$$

$$\gamma_1 = 1, \quad \frac{(1 - \gamma_i)t_i}{\gamma_i^2} \leq \frac{t_{i-1}}{\gamma_{i-1}^2}, \quad i > 1, \quad (5)$$

$$\frac{\gamma_k^2}{t_k} = \mathcal{O}\left(\frac{1}{k^2}\right). \quad (6)$$

- 当取 $t_k = \frac{1}{L}$ ,  $\gamma_k = \frac{2}{k+1}$ 时, 条件(4)(5)(6)满足.
- $\gamma_k$ 的选取并不唯一, 例如可以选取

$$\gamma_1 = 1, \quad \frac{1}{\gamma_k} = \frac{1}{2} \left( 1 + \sqrt{1 + \frac{4}{\gamma_{k-1}}} \right).$$

- 算法(2)和算法(3)都要求步长满足 $t_k \leq \frac{1}{L}$ , 此时条件(4)满足.
- 对绝大多数问题我们不知道函数 $\nabla f$ 的利普希茨常数. 为了在这种情况下条件(4)依然能满足, 需要使用**线搜索**来确定合适的 $t_k$ .
- **线搜索算法1**: 在算法(3)中加入线搜索, 取 $\gamma_k = \frac{2}{k+1}$ , 以回溯的方式找到满足条件(4)的 $t_k$ :

$$\text{重复} \quad \begin{cases} t_k \leftarrow \rho t_k & (\rho < 1) \\ x^k \leftarrow \text{prox}_{t_k h}(y^k - t_k \nabla f(y^k)) \end{cases} \quad \text{直到(4)满足} \quad (7)$$

- 当 $t_k$ 足够小时, 条件(4)是一定会得到满足的, 因此不会出现**线搜索(7)**无法终止的情况.
- 容易验证条件(5)(6)在迭代过程中也得到满足.



► **线搜索算法2:** 在算法(3)中加入线搜索, 不仅改变步长 $t_k$ 而且改变 $\gamma_k$ , 从而 $y^k$ 也随之改变.

$$\text{重复} \left\{ \begin{array}{l} \text{取 } \gamma_k \text{ 为 } t_{k-1}\gamma^2 = t_k\gamma_{k-1}^2(1-\gamma) \text{ 的正根} \\ y^k \leftarrow (1-\gamma_k)x^{k-1} + \gamma_k v^{k-1} \\ x^k \leftarrow \text{prox}_{t_k h}(y^k - t_k \nabla f(y^k)) \\ t_k \leftarrow \rho t_k \end{array} \right. \quad \text{直到(4)成立} \quad (8)$$

- 由算法(8),  $\gamma_k$  满足条件(5)且有  $0 < \gamma_k \leq 1$ ,  $t_k$  有下界  $t_{\min}$ .
- 由  $\sqrt{1-x}$  在点  $x=0$  处的凹性,

$$\begin{aligned} \frac{\sqrt{t_{k-1}}}{\gamma_{k-1}} &= \frac{\sqrt{(1-\gamma_k)t_k}}{\gamma_k} \leq \frac{\sqrt{t_k}}{\gamma_k} - \frac{\sqrt{t_k}}{2} \Rightarrow \frac{\sqrt{t_k}}{\gamma_k} \geq \sqrt{t_1} + \frac{1}{2} \sum_{i=2}^k \sqrt{t_i} \\ \Rightarrow \frac{\gamma_k^2}{t_k} &\leq \frac{1}{\left(\sqrt{t_1} + \frac{1}{2} \sum_{i=2}^k \sqrt{t_i}\right)^2} \leq \frac{4}{t_{\min}(k+1)^2} = \mathcal{O}\left(\frac{1}{k^2}\right). \quad (9) \end{aligned}$$

- (9)说明条件(6)在算法(8)的执行中也得到满足.
- 算法(8)的执行过程比算法(7)的复杂. 由于它同时改变了 $t_k$ 和 $\gamma_k$ , 迭代点 $x^k$ 和参照点 $y^k$ 在线搜索的过程中都发生了变化, 点 $y^k$ 处的梯度也需要重新计算.
- 但此算法给我们带来的好处就是步长 $t_k$ 不再单调下降, 在迭代后期也可以取较大值, 这会进一步加快收敛.

#### ► FISTA算法小结:

- 固定步长的FISTA算法对于步长的选取是较为保守的, 为了保证收敛, 有时不得不选取一个很小的步长, 这使得固定步长的FISTA算法收敛较慢.
- 如果采用线搜索, 则在算法执行过程中会有很大机会选择符合条件的较大步长, 因此线搜索可能加快算法的收敛, 但代价就是每一步迭代的复杂度变高.
- 在实际的FISTA算法中, 需要权衡固定步长和线搜索算法的利弊, 从而选择针对特定问题的高效算法.

## ►下降的FISTA算法

- 原始的FISTA算法不是一个下降算法，这里给出一个FISTA的下降算法变形.
- 只需要对算法(3)的第2步进行修改. 在计算邻近算子之后，我们并不立即选取此点作为新的迭代点，而是检查函数值在当前点处是否下降，只有当函数值下降时才更新迭代点.
- 假设经过近似点映射之后的点为 $u$ ，则对当前点 $x^k$ 做如下更新：

$$x^k = \begin{cases} u, & \psi(u) \leq \psi(x^{k-1}), \\ x^{k-1}, & \psi(u) > \psi(x^{k-1}). \end{cases} \quad (10)$$


- 由于步长或 $\gamma_k$ 会随着 $k$ 变化，(10)式中的 $\psi(u) > \psi(x^{k-1})$ 不会一直成立，即算法不会停留在某个 $x^{k-1}$ 而不进行更新.
- 步长和 $\gamma_k$ 的选取只需使用固定步长 $t_k \leq \frac{1}{L}$ ， $\gamma_k = \frac{2}{k+1}$ 或者使用前述的任意一种线搜索方法均可.

## 第二类Nesterov加速算法

► 复合优化问题(1)的第二类Nesterov加速算法:

$$\begin{cases} z^k = (1 - \gamma_k)x^{k-1} + \gamma_k y^{k-1} \\ y^k = \text{prox}_{(t_k/\gamma_k)h} \left( y^{k-1} - \frac{t_k}{\gamma_k} \nabla f(z^k) \right) \\ x^k = (1 - \gamma_k)x^{k-1} + \gamma_k y^k \end{cases} \quad (11)$$

$$y^k = \text{prox}_{(t_k/\gamma_k)h} (y^{k-1} - (t_k/\gamma_k) \nabla f(z^k))$$



- 和FISTA 算法(3)的一个重要区别在于, 第二类Nesterov 加速算法(11)中的三个序列 $\{x^k\}$ ,  $\{y^k\}$ 和 $\{z^k\}$ 都可以保证在定义域内. 而FISTA 算法中的序列 $\{y^k\}$ 不一定在定义域内.

### 第三类Nesterov加速算法

► 复合优化问题(1)的第三类Nesterov加速算法:

$$\begin{cases} z^k = (1 - \gamma_k)x^{k-1} + \gamma_k y^{k-1} \\ y^k = \text{prox}_{(t_k \sum_{i=1}^k 1/\gamma_i)h} \left( -t_k \sum_{i=1}^k \frac{1}{\gamma_i} \nabla f(z^i) \right) \\ x^k = (1 - \gamma_k)x^{k-1} + \gamma_k y^k \end{cases} \quad (12)$$

- 第三类Nesterov 加速算法(12)和第二类Nesterov加速算法(11)的区别仅仅在于 $y^k$ 的更新: 第三类Nesterov 加速算法(12)计算 $y^k$ 时需要利用全部已有的 $\{\nabla f(z^i)\}, i = 1, 2, \dots, k$ .
- 该算法取 $\gamma_k = \frac{2}{k+1}$ ,  $t_k = \frac{1}{L}$ 时, 也有 $\mathcal{O}\left(\frac{1}{k^2}\right)$ 的收敛速度.

## Nesterov 加速算法应用: LASSO问题

### ► LASSO问题:

$$\min_x \frac{1}{2} \|Ax - b\|_2^2 + \mu \|x\|_1. \quad (13)$$

- 求解LASSO问题(13)的FISTA算法:

$$\begin{aligned} y^k &= x^{k-1} + \frac{k-2}{k+1} (x^{k-1} - x^{k-2}), \\ w^k &= y^k - t_k A^T (Ay^k - b), \\ x^k &= \text{sign}(w^k) \max\{|w^k| - t_k \mu, 0\}. \end{aligned}$$

与近似点梯度算法相同, 由于最后一步将 $w^k$ 中绝对值小于 $t_k \mu$ 的分量置零, 该算法能够保证迭代过程中解具有稀疏结构.

- 求解LASSO问题(13)的第二类Nesterov加速算法:

$$\begin{aligned}z^k &= (1 - \gamma_k)x^{k-1} + \gamma_k y^{k-1}, \\w^k &= y^{k-1} - \frac{t_k}{\gamma_k} A^T (Az^k - b), \\y^k &= \text{sign}(w^k) \max \left\{ |w^k| - \frac{t_k}{\gamma_k} \mu, 0 \right\}, \\x^k &= (1 - \gamma_k)x^{k-1} + \gamma_k y^k.\end{aligned}$$

- 求解LASSO问题(13)的第三类Nesterov加速算法:

$$\begin{aligned}z^k &= (1 - \gamma_k)x^{k-1} + \gamma_k y^{k-1}, \\w^k &= -t_k \sum_{i=1}^k \frac{1}{\gamma_i} A^T (Az^i - b), \\y^k &= \text{sign}(w^k) \max \left\{ |w^k| - t_k \sum_{i=1}^k \frac{1}{\gamma_i} \mu, 0 \right\}, \\x^k &= (1 - \gamma_k)x^{k-1} + \gamma_k y^k.\end{aligned}$$

- 取  $\mu = 10^{-3}$ , 分别利用近似点梯度法、FISTA算法、第二类Nesterov算法来求解(13), 分别取固定步长  $t = \frac{1}{L}$ , 其中  $L = \lambda_{\max}(A^T A)$ , 和结合线搜索的BB步长.




Figure 2: 固定步长, FISTA算法相较于第二类Nesterov加速算法收敛得略快一些; FISTA算法是非单调的; BB步长和线搜索技巧可以加速算法的收敛速度; 带线搜索的近似点梯度法可以比带线搜索的FISTA算法更快收敛.



## 固定步长FISTA算法收敛速度

收敛性假设:

- $f$  在其定义域  $\text{dom } f = \mathbb{R}^n$  内凸, 且是  $L$ -光滑的

$$\|\nabla f(x) - \nabla f(y)\| \leq L\|x - y\|, \quad \forall x, y \in \text{dom } f.$$

- $h$  是适当的闭凸函数.
- $\psi(x)$  的最小值  $\psi^*$  是有限的, 且在点  $x^*$  处可以取到.

► 固定步长近似点梯度法的收敛速度为  $\mathcal{O}(1/k)$ , 而固定步长FISTA算法则可以加速到  $\mathcal{O}(1/k^2)$ .

**Theorem 1.** 在收敛性假设的条件下, 当用FISTA算法(3)求解凸复合优化问题(1) 时, 若取固定步长  $t_k = \frac{1}{L}$ , 则

$$\psi(x^k) - \psi(x^*) \leq \frac{2L}{(k+1)^2} \|x^0 - x^*\|^2. \quad (14)$$

## 定理1的证明

- 根据  $x^k = \text{prox}_{t_k h}(y^k - t_k \nabla f(y^k))$ , 可知

$$-x^k + y^k - t_k \nabla f(y^k) \in t_k \partial h(x^k).$$

故对于任意的  $x$ , 有

$$t_k h(x) \geq t_k h(x^k) + \langle -x^k + y^k - t_k \nabla f(y^k), x - x^k \rangle. \quad (15)$$

- 由  $f$  的凸性、 $L$ -光滑和  $t_k = \frac{1}{L}$  可得,

$$f(x^k) \leq f(y^k) + \langle \nabla f(y^k), x^k - y^k \rangle + \frac{1}{2t_k} \|x^k - y^k\|^2. \quad (16)$$

- 结合(15)和(16), 对于任意的 $x$ 有

$$\begin{aligned}
 \psi(x^k) &= f(x^k) + h(x^k) \\
 &\leq h(x) + f(y^k) + \langle \nabla f(y^k), x - y^k \rangle + \frac{1}{t_k} \langle x^k - y^k, x - x^k \rangle \\
 &\quad + \frac{1}{2t_k} \|x^k - y^k\|^2 \\
 &\leq h(x) + f(x) + \frac{1}{t_k} \langle x^k - y^k, x - x^k \rangle + \frac{1}{2t_k} \|x^k - y^k\|^2 \\
 &= \psi(x) + \frac{1}{t_k} \langle x^k - y^k, x - x^k \rangle + \frac{1}{2t_k} \|x^k - y^k\|^2.
 \end{aligned} \tag{17}$$

- 在(17)式中分别取 $x = x^{k-1}$ 和 $x = x^*$ , 并记 $\psi(x^*) = \psi^*$ , 再分别乘 $1 - \gamma_k$ 和 $\gamma_k$ 并相加得到

$$\begin{aligned}
 &\psi(x^k) - \psi^* - (1 - \gamma_k)(\psi(x^{k-1}) - \psi^*) \\
 &\leq \frac{1}{t_k} \langle x^k - y^k, (1 - \gamma_k)x^{k-1} + \gamma_k x^* - x^k \rangle + \frac{1}{2t_k} \|x^k - y^k\|^2.
 \end{aligned} \tag{18}$$

- 由  $v^k = x^{k-1} + \frac{1}{\gamma_k}(x^k - x^{k-1})$ ,  $y^k = (1 - \gamma_k)x^{k-1} + \gamma_k v^{k-1}$  知, 不等式(18)可以化为

$$\begin{aligned}
 & \psi(x^k) - \psi^* - (1 - \gamma_k)(\psi(x^{k-1}) - \psi^*) \\
 & \leq \frac{1}{2t_k} (\|y^k - (1 - \gamma_k)x^{k-1} - \gamma_k x^*\|^2 - \|x^k - (1 - \gamma_k)x^{k-1} - \gamma_k x^*\|^2) \\
 & = \frac{\gamma_k^2}{2t_k} (\|v^{k-1} - x^*\|^2 - \|v^k - x^*\|^2).
 \end{aligned} \tag{19}$$

- $t_k, \gamma_k$  的取法满足不等式  $\frac{1 - \gamma_k}{\gamma_k^2} t_k \leq \frac{1}{\gamma_{k-1}^2} t_{k-1}$ , 因此,

$$\frac{t_k}{\gamma_k^2} (\psi(x^k) - \psi^*) + \frac{1}{2} \|v^k - x^*\|^2 \leq \frac{t_{k-1}}{\gamma_{k-1}^2} (\psi(x^{k-1}) - \psi^*) + \frac{1}{2} \|v^{k-1} - x^*\|^2. \tag{20}$$

- 根据(20),

$$\frac{t_k}{\gamma_k^2}(\psi(x^k) - \psi^*) + \frac{1}{2}\|v^k - x^*\|^2 \leq \frac{t_1}{\gamma_1^2}(\psi(x^1) - \psi^*) + \frac{1}{2}\|v^1 - x^*\|^2. \quad (21)$$

- 对 $k = 1$ , 注意到 $\gamma_1 = 1, v^0 = x^0$ , 再次利用(19)可得

$$\begin{aligned} & \frac{t_1}{\gamma_1^2}(\psi(x^1) - \psi^*) + \frac{1}{2}\|v^1 - x^*\|^2 \\ & \leq \frac{(1 - \gamma_1)t_1}{\gamma_1^2}(\psi(x^0) - \psi^*) + \frac{1}{2}\|v^0 - x^*\|^2 = \frac{1}{2}\|x^0 - x^*\|^2. \end{aligned} \quad (22)$$

由(21)和(22)可得(14)成立.

► **Remark:**

- 定理1的证明关键的一步在于建立(20), 而建立这个递归关系并不需要 $t = 1/L, \gamma_k = 2/(k+1)$ 这一具体条件, 只需要保证条件(4)和条件(5)成立即可.
- 条件(4)主要依赖于 $f(x)$ 的 $L$ -光滑性, (5)的成立依赖于 $\gamma_k$ 和 $t_k$ 的选取. 条件(6)的成立保证了算法(3)的收敛速度达到 $\mathcal{O}\left(\frac{1}{k^2}\right)$ . 如果将条件(4)-(6)作为算法收敛的假设条件, 则可以证明一大类FISTA算法的变形都具有 $\mathcal{O}\left(\frac{1}{k^2}\right)$ 的收敛速度.

## 第二类Nesterov加速算法的收敛速度

**Theorem 2.** 利用算法(11)求解问题(1), 取 $\gamma_k = \frac{2}{k+1}$  和 $t_k = \frac{1}{L}$ , 设 $\{x^k\}$ 是算法(11)产生的迭代序列, 则在收敛性假设成立的条件下, 有

$$\psi(x^k) - \psi(x^*) \leq \frac{2L}{(k+1)^2} \|x^0 - x^*\|^2. \quad (23)$$

*Proof.* 根据 $y^k = \text{prox}_{(t_k/\gamma_k)h} \left( y^{k-1} - \left( \frac{t_k}{\gamma_k} \right) \nabla f(z^k) \right)$ ,

$$\gamma_k(y^{k-1} - y^k) - t_k \nabla f(z^k) \in t_k \partial h(y^k),$$

故对于任意的 $x$ ,有

$$t_k h(x) \geq t_k h(y^k) + \langle \gamma_k(y^{k-1} - y^k) - t_k \nabla f(z^k), x - y^k \rangle.$$

由 $h$ 的凸性,

$$h(x^k) \leq (1 - \gamma_k)h(x^{k-1}) + \gamma_k h(y^k),$$

消去 $h(y^k)$ 得到,

$$\begin{aligned} h(x^k) &\leq (1 - \gamma_k)h(x^{k-1}) \\ &\quad + \gamma_k \left[ h(x) - \left\langle \frac{\gamma_k}{t_k}(y^{k-1} - y^k) - \nabla f(z^k), x - y^k \right\rangle \right]. \end{aligned} \quad (24)$$

利用 $f$ 的凸性和 $L$ -光滑性,

$$\begin{aligned} f(x^k) &\leq f(z^k) + \langle \nabla f(z^k), x^k - z^k \rangle + \frac{L}{2} \|x^k - z^k\|^2 \\ &= f(z^k) + \langle \nabla f(z^k), x^k - z^k \rangle + \frac{1}{2t_k} \|x^k - z^k\|^2. \end{aligned} \quad (25)$$

由算法(11)知,

$$x^k - z^k = \gamma_k(y^k - y^{k-1}), \quad x^k = (1 - \gamma_k)x^{k-1} + \gamma_k y^k.$$

于是根据(25),

$$f(x^k) \leq f(z^k) + \langle \nabla f(z^k), (1 - \gamma_k)x^{k-1} + \gamma_k y^k - z^k \rangle + \frac{\gamma_k^2}{2t_k} \|y^k - y^{k-1}\|^2. \quad (26)$$

注意到

$$\begin{aligned} & f(z^k) + \langle \nabla f(z^k), (1 - \gamma_k)x^{k-1} + \gamma_k y^k - z^k \rangle \\ &= (1 - \gamma_k)[f(z^k) + \langle \nabla f(z^k), x^{k-1} - z^k \rangle] + \gamma_k[f(z^k) + \langle \nabla f(z^k), y^k - z^k \rangle] \\ &\leq (1 - \gamma_k)f(x^{k-1}) + \gamma_k[f(z^k) + \langle \nabla f(z^k), y^k - z^k \rangle], \end{aligned} \quad (27)$$

由(26)和(27)得,

$$f(x^k) \leq (1 - \gamma_k)f(x^{k-1}) + \gamma_k[f(z^k) + \langle \nabla f(z^k), y^k - z^k \rangle] + \frac{\gamma_k^2}{2t_k} \|y^k - y^{k-1}\|^2. \quad (28)$$



将(24)与(28)相加, 并结合  $f(x) \geq f(z^k) + \langle \nabla f(z^k), x - z^k \rangle$ , 再取  $x = x^*$ , 可得

$$\begin{aligned} & \psi(x^k) - (1 - \gamma_k)\psi(x^{k-1}) \\ & \leq \gamma_k \left[ h(x^*) + f(x^*) - \frac{\gamma_k}{t_k} \langle y^{k-1} - y^k, x^* - y^k \rangle \right] + \frac{\gamma_k^2}{2t_k} \|y^k - y^{k-1}\|^2 \quad (29) \\ & \leq \gamma_k \psi(x^*) + \frac{\gamma_k^2}{2t_k} (\|y^{k-1} - x^*\|^2 - \|y^k - x^*\|^2). \end{aligned}$$

这个不等式和(19)的形式完全相同, 因此后续过程可按照定理1 进行推导, 可以得到(23). □

►一般第二类Nesterov加速算法的收敛速度: 用算法(11)求解凸复合优化问题(1), 若迭代点  $x^k, y^k$ , 步长  $t_k$  以及组合系数  $\gamma_k$  满足条件(4)—(6), 则

$$\psi(x^k) - \psi(x^*) \leq \frac{C}{k^2}, \quad (30)$$

其中  $C$  仅和函数  $f$ , 初始点  $x^0$  的选取有关.