

机器学习中的优化算法

Lecture08: 复合优化算法-近似点算法

张立平

清华大学数学科学系

办公室：理科楼#A302, Tel: 62798531

E-mail: lipingzhang@tsinghua.edu.cn

Contents and Acknowledgement

- 教材：最优化：建模、算法与理论

<http://bicmr.pku.edu.cn/wenzw/bigdata2021.html>

- 致谢：北京大学文再文教授

Outline of Lecture08

- 近似点算法
- 与ALM的关系
- 应用: LASSO问题
- 收敛性分析
- Moreau-Yosida正则化
- 对偶近似点梯度与交替极小化方法

近似点算法

► 考虑优化问题

$$\min_x \psi(x) \quad (1)$$

其中 ψ 是一个适当的闭凸函数,并不要求连续或可微.

- 次梯度法, 收敛较慢, 且收敛条件苛刻: $x^{k+1} = x^k - t_k \partial \psi(x^{k+1})$.
- 近似点算法:

$$\begin{aligned} x^{k+1} &= \text{prox}_{t_k \psi} (x^k) \\ &= \arg \min_u \left\{ \psi(u) + \frac{1}{2t_k} \|u - x^k\|_2^2 \right\}, \end{aligned} \quad (2)$$

其中 t_k 为第 k 步迭代时的步长, 可为固定值或通过某种合适的线搜索策略得到. 近似点算法(2)可看作近似点梯度法的特殊情况, $\psi(x)$ 的邻近算子一般需要通过迭代求解, 但(2)的目标函数强凸, 相比原问题更利于迭代法的求解.

加速近似点算法

► 针对近似点算法(2)的FISTA加速:

$$x^k = \text{prox}_{t_k \psi} \left(x^{k-1} + \gamma_k \frac{1 - \gamma_{k-1}}{\gamma_{k-1}} (x^{k-1} - x^{k-2}) \right) \quad (3)$$

► 针对近似点算法(2)的第二类Nesterov加速:

$$v^k = \text{prox}_{(t_k/\gamma_k)\psi} (v^{k-1}), \quad x^k = (1 - \gamma_k) x^{k-1} + \gamma_k v^k. \quad (4)$$

► 关于算法参数选择的两种策略:

- 固定步长 $t_k = t$ 以及 $\gamma_k = \frac{2}{k+1}$;
- 可变步长 t_k , 当 $k=1$ 时取 $\gamma_1 = 1$; 当 $k > 1$ 时, γ_k 满足:

$$\frac{(1 - \gamma_k) t_k}{\gamma_k^2} = \frac{t_{k-1}}{\gamma_{k-1}^2}.$$

近似点算法与增广拉格朗日函数法的关系

► 考虑具有如下形式的优化问题:

$$\min_{x \in \mathbb{R}^n} f(x) + h(Ax) \quad (5)$$

其中 f, h 为适当的闭凸函数, $A \in \mathbb{R}^{m \times n}$.

- 当 h 是单点集 $\{b\}$ 的示性函数时, $(5) \iff \min f(x), \text{ s.t. } Ax = b.$
- 当 h 是凸集 C 上的示性函数时, $(5) \iff \min f(x), \text{ s.t. } Ax \in C.$
- 当 $h(y) = \|y - b\|$ 时, $(5) \iff \min f(x) + \|Ax - b\|.$

► 优化问题(5)的拉格朗日对偶问题为:

$$\max \quad \psi(z) = \inf_{x, y} \{f(x) + h(y) + z^T (Ax - y)\} = -f^*(-A^T z) - h^*(z) \quad (6)$$

► 对对偶问题(6)用近似点算法 \iff 对原问题(5)用增广拉格朗日函数法

Lemma 1. 设 $f(x)$ 是适当的闭凸函数, $f^*(y)$ 是其共轭函数, 则对任意的 $y \in \text{dom } f^*$ 和 $x \in \text{dom } f$ 有

$$y \in \partial f(x) \iff x \in \partial f^*(y). \quad (7)$$

► 对对偶问题(6)用近似点算法 \iff 对原问题(5)用增广拉格朗日函数法

对原问题(5), 增广拉格朗日函数法迭代格式如下:

$$(x^{k+1}, y^{k+1}) = \arg \min_{x, y} \left\{ f(x) + h(y) + \frac{t_k}{2} \|Ax - y + \frac{1}{t_k} z^k\|^2 \right\},$$

乘子更新 $z^{k+1} = z^k + t_k (Ax^{k+1} - y^{k+1}).$

对对偶问题(6), 近似点算法迭代格式如下:

$$z^{k+1} = \text{prox}_{t\psi} (z^k) = \arg \min_z \left\{ f^* (-A^T z) + h^*(z) + \frac{1}{2t_k} \|z - z^k\|_2^2 \right\}$$

事实上也可以写成: $z^{k+1} = \text{prox}_{t\psi}(z^k) = z^k + t^k (A\hat{x} - \hat{y})$, 其中

$$(\hat{x}, \hat{y}) = \arg \min_{x, y} \left(f(x) + h(y) + z^T (Ax - y) + \frac{t}{2} \|Ax - y\|_2^2 \right). \quad (8)$$

也就是说, \hat{x}, \hat{y} 最小化增广拉格朗日函数, 近似点算法迭代格式对应增广拉格朗日函数法中的乘子更新.

Proof. 考虑(8)的等价问题

$$\begin{aligned} \min_{x,y,w} \quad & f(x) + h(y) + \frac{t}{2} \|w\|_2^2 \\ \text{s.t.} \quad & Ax - y + z/t = w. \end{aligned}$$

设 u 为约束 $Ax - y + \frac{z}{t} = w$ 的拉格朗日乘子, 由最优性条件知

$$A\hat{x} - \hat{y} + \frac{z}{t} = w, \quad -A^T u \in \partial f(\hat{x}), \quad u \in \partial h(\hat{y}), \quad tw = u.$$

于是, 根据(7)得:

$$u = z + t(A\hat{x} - \hat{y}), \quad \hat{x} \in \partial f^*(-A^T u), \quad \hat{y} \in \partial h^*(u).$$

因此,

$$0 \in -A\partial f^*(-A^T u) + \partial h^*(u) + \frac{1}{t}(u - z).$$

这正是 $u = \text{prox}_{t\psi}(z)$ 的最优性条件.

另一方面, 若有 $u = \text{prox}_{t\psi}(z)$, 则选取 $\hat{x} \in \partial f^*(-A^T u)$ 及 $\hat{y} \in \partial h^*(u)$, 即可恢复出增广拉格朗日函数法中的变量. □

应用: LASSO问题

考虑LASSO问题:

$$\min \mu \|x\|_1 + \frac{1}{2} \|Ax - b\|_2^2 \iff \begin{cases} \min_{x,y} f(x,y) = \mu \|x\|_1 + \frac{1}{2} \|y\|_2^2 \\ \text{s.t. } Ax - y - b = 0. \end{cases} \quad (9)$$

用近似点算法进行求解(9), 第 k 步迭代为

$$(x^{k+1}, y^{k+1}) \approx \arg \min_{(x,y) \in \mathcal{D}} \left\{ f(x,y) + \frac{1}{2t_k} \left(\|x - x^k\|_2^2 + \|y - y^k\|_2^2 \right) \right\}, \quad (10)$$

其中 $\mathcal{D} = \{(x,y) \mid Ax - y = b\}$, t_k 为步长.

由于问题(10)没有显式解, 我们需要采用迭代算法(比如罚函数法, 增广拉格朗日方法等)来进行求解. 另一种比较实用的方式是通过构造对偶问题的解来构造 (x^{k+1}, y^{k+1}) .

问题(10)的Lagrangian对偶函数为:

$$\begin{aligned}
 \Phi_k(z) &= \inf_x \left\{ \mu \|x\|_1 + z^T A x + \frac{1}{2t_k} \|x - x^k\|_2^2 \right\} \\
 &\quad + \inf_y \left\{ \frac{1}{2} \|y\|_2^2 - z^T y + \frac{1}{2t_k} \|y - y^k\|_2^2 \right\} - b^T z \\
 &= \mu \Gamma_{\mu t_k}(x^k - t_k A^T z) - \frac{1}{2t_k} \left(\|x_k - t_k A^T z\|_2^2 - \|x_k\|_2^2 \right) \\
 &\quad - \frac{1}{2(t_k + 1)} (t_k \|z\|_2^2 + 2(y^k)^T z - \|y^k\|_2^2) - b^T z.
 \end{aligned}$$

其中

$$\Gamma_{\mu t_k}(u) = \inf_x \left\{ \|x\|_1 + \frac{1}{2\mu t_k} \|x - u\|_2^2 \right\}.$$

记函数 $q_{\mu t_k} : \mathbb{R} \rightarrow \mathbb{R}$ 为

$$q_{\mu t_k}(v) = \begin{cases} \frac{v^2}{2\mu t_k}, & |v| \leq \mu t_k, \\ |v| - \frac{\mu t_k}{2}, & |v| > \mu t_k, \end{cases}$$

通过简单地计算, $\Gamma_{\mu t_k}(u) = \sum_{i=1}^n q_{\mu t_k}(u_i)$ 且为极小点 $x = \text{prox}_{\mu t_k \|x\|_1}(u)$ 处的目标函数值. 易知 $\Gamma_{\mu t_k}(u)$ 是关于 u 的连续可微函数且

$$\nabla_u \Gamma_{\mu t_k}(u) = \frac{u - \text{prox}_{\mu t_k \|x\|_1}(u)}{\mu t_k}.$$

设对偶问题的逼近最优解为 z^{k+1} , 则根据问题(10)的最优性条件,

$$\begin{cases} x^{k+1} = \text{prox}_{\mu t_k \|x\|_1} \left(x^k - t_k A^T z^{k+1} \right), \\ y^{k+1} = \frac{1}{t_k + 1} (y^k + t_k z^{k+1}). \end{cases}$$

于是, LASSO (9) 问题的近似点算法的迭代格式为:

$$\begin{cases} z^{k+1} \approx \arg \max_z \Phi_k(z), \\ x^{k+1} = \text{prox}_{\mu t_k \|x\|_1} \left(x^k - t_k A^T z^{k+1} \right), \\ y^{k+1} = \frac{1}{t_k + 1} (y^k + t_k z^{k+1}). \end{cases} \quad (11)$$

注: 根据 $\Phi_k(z)$ 的连续可微性, 可以调用梯度法进行求解. 可以证明 $\Phi_k(z)$ 是半光滑的, 从而可调用半光滑牛顿法来更有效地求解.

为了保证算法(11)的收敛性, 我们采用以下不精确收敛准则:

$$\begin{aligned} \epsilon_k &\geq 0, \quad \sum_k \epsilon_k < \infty; \quad \delta_k \geq 0, \quad \sum_k \delta_k < \infty, \\ \|\nabla \Phi_k(z^{k+1})\|_2 &\leq \sqrt{\alpha/t_k} \epsilon_k, \\ \|\nabla \Phi_k(z^{k+1})\|_2 &\leq \sqrt{\alpha/t_k} \delta_k \|(x^{k+1}, y^{k+1}) - (x^k, y^k)\|^2, \end{aligned} \quad (12)$$

其中 ϵ_k, δ_k 是人为设定的参数, α 为 $-\Phi_k$ 的强凸参数.

► $m = 512; n = 1024; A = \text{randn}(m, n); u = \text{sprandn}(n, 1, r); b = A * u$; 取固定步长 $t = 10^3$, 精度参数设置为 $\alpha_k = \frac{t}{t+1}$, $\epsilon_k = \delta_k = \frac{8}{k^2}$




Figure 1: PPA 求解LASSO 问题: PPA收敛所需的外部迭代数很少.

近似点算法(PPA)收敛性分析

基本假设A:

- ψ 是闭凸函数 (因此, 对 $\forall x$, $\text{prox}_{t\psi}(x)$ 唯一确定)
- 最优值 ψ^* 有限且在 x^* 取到

结论I: 在**基本假设A**成立的条件下, 近似点算法(2)的收敛性

$$\psi(x^{(k)}) - \psi^* \leq \frac{\|x^{(0)} - x^*\|_2^2}{2 \sum_{i=1}^k t_i} \quad \forall k \geq 1.$$

- $\sum_i t_i \rightarrow \infty$ 时收敛
- 若 t_i 固定或在一个正下界以上变化, 则收敛速率为 $1/k$
- t_i 可以任意选取, 然而邻近算子的计算代价依赖于 t_i

Proof. PPA就是对原问题应用近似点梯度法(即 $f(x) = 0$ 的情形), 则下式在 $t > 0$ 的情形下自然满足:

$$f(x - tG_t(x)) \leq f(x) + t\nabla f(x)^T G_t(x) + \frac{t}{2} \|G_t(x)\|_2^2$$

根据近似点梯度法收敛性的证明, 我们有

$$t_i (\psi(x^i) - \psi^*) \leq \frac{1}{2} \left(\|x^{i-1} - x^*\|_2^2 - \|x^i - x^*\|_2^2 \right)$$

且 $\{\psi(x^i)\}$ 是单调下降的序列. 因此

$$\left(\sum_{i=1}^k t_i \right) (\psi(x^k) - \psi^*) \leq \sum_{i=1}^k t_i (\psi(x^i) - \psi^*) \leq \frac{1}{2} \|x^0 - x^*\|_2^2.$$

□

加速近似点算法的收敛性分析

结论II: 在**基本假设A**成立的条件下, 加速近似点算法(3)-(4)的收敛性

$$\psi(x^{(k)} - \psi^*) \leq \frac{2\|x^{(0)} - x^*\|_2^2}{(2\sqrt{t_1} + \sum_{i=2}^k \sqrt{t_i})^2}, \quad k \geq 1.$$

- 若 $\sum_i \sqrt{t_i} \rightarrow \infty$, 则加速近似点算法(3)-(4)保证收敛
- 步长 t_i 取固定值或有正下界时, 其收敛速度可达到 $\mathcal{O}(\frac{1}{k^2})$
(实际上也需控制 t_i 上界以便子问题可快速求解)

Proof. 加速近似点算法(3)-(4)就是在 $f(x) = 0$ 的情况下对(1)使用FISTA或第二类Nesterov加速算法, 利用FISTA或第二类Nesterov加速算法收敛性定理的证明.

由于 $f(x) = 0$, 对任意的 $t > 0$,

$$f(x) \leq f(y) + \nabla f(y)^T(x - y) + \frac{1}{2t}\|x - y\|_2^2, \quad \forall x, y$$

于是

$$\psi(x^k) - \psi^* \leq \frac{\gamma_k^2}{2t_k} \|x^0 - x^*\|_2^2. \quad (13)$$

取固定步长 $t_k = t$ 和 $\gamma_k = \frac{2}{k+1}$, 则

$$\frac{\gamma_k^2}{2t_k} = \frac{2}{(k+1)^2 t}$$

对于变步长,

$$\frac{\gamma_k^2}{2t_k} \leq \frac{2}{\left(2\sqrt{t_1} + \sum_{i=2}^k \sqrt{t_i}\right)^2}$$

分别由(13) 及第二类Nesterov加速算法收敛性定理的证明, 可得结论II. \square

Moreau-Yosida 正则化

闭凸函数 f 的Moreau-Yosida正则化 (又称为Moreau envelope) 定义为

$$\begin{aligned} f_{(t)}(x) &= \inf_u \left(f(u) + \frac{1}{2t} \|u - x\|_2^2 \right) \quad (t > 0) \\ &= f(\text{prox}_{tf}(x)) + \frac{1}{2t} \|\text{prox}_{tf}(x) - x\|_2^2. \end{aligned} \tag{14}$$

- $f_{(t)}$ 是凸函数 (一个以 x, u 为自变量的凸函数对 u 取下确界)
- $f_{(t)}$ 的定义域为 \mathbb{R}^n ($\text{prox}_{tf}(x)$ 对于任意的 x 存在且唯一)
- Moreau envelope 分解 $f_{(t)}(x) + f_{(t-1)}^*(x) = \frac{\|x\|^2}{2t}$


【例1】示性函数 f 的Moreau envelope是Euclid距离的平方

$$f(x) = I_C(x), \quad f_{(t)}(x) = \frac{1}{2t} d(x)^2.$$

【例2】 l_1 范数的 Moreau envelope 是 Huber 损失函数

$$f(x) = \|x\|_1, \quad f_{(t)}(x) = \sum_{k=1}^n \phi_t(x_k),$$

$$\phi_t(z) = \begin{cases} z^2/(2t) & |z| \leq t \\ |z| - t/2 & |z| \geq t \end{cases}$$



Moreau envelope的共轭函数

考虑闭凸函数 f 的Moreau envelope

$$f_{(t)}(x) = \inf_u \left(f(u) + \frac{1}{2t} \|u - x\|_2^2 \right).$$

- $f_{(t)}$ 是 $f(u)$ 与 $\|v\|_2^2/(2t)$ 的卷积下确界:

$$f_{(t)}(x) = \inf_{u+v=x} \left(f(u) + \frac{1}{2t} \|v\|_2^2 \right).$$

- $f_{(t)}$ 的共轭是 $f(u)$ 的共轭与 $\|v\|_2^2/(2t)$ 的和:

$$(f_{(t)})^*(y) = f^*(y) + \frac{t}{2} \|y\|_2^2.$$

- $f_{(t)}$ 的共轭是 t -强凸的.

设 $f(x)$ 是适当且闭的强凸函数, 强凸参数为 $\mu > 0$, 则 $f^*(y)$ 在全空间 \mathbb{R}^n 上有定义, 且是 $\frac{1}{\mu}$ -光滑函数.

Moreau envelope的梯度

$$f_{(t)}(x) = \sup_y (x^T y - (f_{(t)})^*(y)) = \sup_y (x^T y - f^*(y) - \frac{t}{2} \|y\|_2^2).$$

- 最大值点 y 唯一且满足:

$$\frac{x}{t} - \partial \frac{f^*(y)}{t} - y = 0 \iff y = \arg \min_u \left(\frac{f^*(u)}{t} + \frac{1}{2} \|u - \frac{x}{t}\|^2 \right).$$

- $x \in \partial(f_{(t)})^*(y) \iff y \in \partial f_{(t)}(x)$, 根据**唯一性**, 最大值点 y 即是 $f_{(t)}$ 的梯度:

$$\nabla f_{(t)}(x) = \text{prox}_{(1/t)f^*}(x/t) = \frac{1}{t}(x - \text{prox}_{tf}(x)).$$

- 梯度 $\nabla f_{(t)}$ 为 $(1/t)$ -利普希茨连续

根据邻近算子性质: $\|\text{prox}_h(\mathbf{x}_1) - \text{prox}_h(\mathbf{x}_2)\|_2 \leq \|\mathbf{x}_1 - \mathbf{x}_2\|_2$ 可得.

近似点算法的解释

- 使用梯度法来最小化 f 的 **Moreau envelope**

$$\min_x f_{(t)}(x) = \inf_u \left(f(u) + \frac{1}{2t} \|u - x\|_2^2 \right). \quad (15)$$

这是最小化 $f(x)$ 优化问题的 **光滑化形式**，且满足：

- 问题(15)的最优值点 x 同时也是原问题 f 的最小值点
- $f_{(t)}$ 可微且梯度利普希茨连续 ($L = 1/t$)

- 我们可以使用固定步长： $t_k = 1/L = t$

$$x^{(k)} = x^{(k-1)} - t \nabla f_{(t)}(x^{(k-1)}) = \text{prox}_{tf}(x^{(k-1)}).$$

这就是 **min** $f(x)$ 的固定步长近似点算法的迭代格式.

增广拉格朗日函数法的解释

► 考虑求解问题(5)的增广拉格朗日函数法迭代:

$$(\hat{x}, \hat{y}) = \underset{x, y}{\operatorname{argmin}} \left(f(x) + h(y) + \frac{t}{2} \|Ax - y + (1/t)z\|_2^2 \right)$$

乘子更新

$$z = z + t(A\hat{x} - \hat{y})$$

- 固定步长 t , 对偶乘子更新即为对光滑化的对偶问题使用梯度下降

$$z^{k+1} = \operatorname{prox}_{t\psi} \left(z^k \right) = \arg \min_z \left\{ f^* \left(-A^T z \right) + h^*(z) + \frac{1}{2t} \|z - z^k\|_2^2 \right\}$$

- 如果我们消去 y , 关键变量 x 的更新可以理解为光滑化 h :

$$\hat{x} = \underset{x}{\operatorname{argmin}} \left(f(x) + h_{(1/t)}(Ax + (1/t)z) \right).$$

► **【例】** $\min f(x) + \|Ax - b\|_1$

$$\hat{x} = \underset{x}{\operatorname{argmin}} \left(f(x) + \phi_{1/t}(Ax - b + (1/t)z) \right),$$

其中 $\phi_{1/t}$ 表示将Huber损失函数应用到各分量.

交替极小化方法与对偶近似点梯度法

设 f, h 闭凸函数, 考虑优化问题(5)及其对偶问题(6):

$$(P) \quad \min_{x \in \mathbb{R}^n} \quad \psi(x) = f(x) + h(Ax),$$

$$(D) \quad \max_z \quad \phi(z) = -f^*(-A^T z) - h^*(z).$$

- f 是可微 μ -强凸函数 $\Rightarrow f^*(-A^T z)$ 是 $\frac{1}{\mu}$ -光滑的

$$\|A \nabla f^*(-A^T z_1) - A \nabla f^*(-A^T z_2)\|_2 \leq \frac{\|A\|_2^2}{\mu} \|z_1 - z_2\|_2.$$

- PG求解(D)的迭代:

$$z^{k+1} = \text{prox}_{th^*} \left(z^k + tA \nabla f^* \left(-A^T z^k \right) \right) \quad (16)$$

引入变量 $x^{k+1} = \nabla f^*(-A^T z^k)$, 迭代格式(16)等价于

$$x^{k+1} = \arg \min_x \left\{ f(x) + \left(A^T z^k \right)^T x \right\}, \quad z^{k+1} = \text{prox}_{th^*} \left(z^k + tA x^{k+1} \right)$$

- 由 $h^{**} = h$ 及 Moreau 分解, 得

$$\begin{aligned} z^k + tAx^{k+1} &= \text{prox}_{th^*}(z^k + tAx^{k+1}) + t\text{prox}_{t^{-1}h}\left(\frac{z^k}{t} + Ax^{k+1}\right) \\ &= z^{k+1} + t\text{prox}_{t^{-1}h}\left(\frac{z^k}{t} + Ax^{k+1}\right), \end{aligned}$$

- 对偶近似点梯度法针对原问题(P)的更新:

$$\begin{aligned} x^{k+1} &= \arg \min_x \left\{ f(x) + (z^k)^\top Ax \right\}, \\ y^{k+1} &= \text{prox}_{t^{-1}h}\left(\frac{z^k}{t} + Ax^{k+1}\right) \\ &= \arg \min_y \left\{ h(y) - (z^k)^\top (y - Ax^{k+1}) + \frac{t}{2} \|Ax^{k+1} - y\|_2^2 \right\}, \\ z^{k+1} &= z^k + t(Ax^{k+1} - y^{k+1}). \end{aligned} \tag{17}$$

交替极小化方法

- (P)的等价问题:

$$\min_{x,y} f(x) + h(y), \quad \text{s.t. } y = Ax.$$

- (P)的拉格朗日函数和增广拉格朗日函数:

$$L(x, y, z) = f(x) + h(y) - z^T(y - Ax)$$

$$L_t(x, y, z) = f(x) + h(y) - z^T(y - Ax) + \frac{t}{2}\|y - Ax\|^2$$

- 交替极小化方法迭代格式:

$$x^{k+1} = \arg \min_x L(x, y^k, z^k)$$

$$y^{k+1} = \arg \min_y L_t(x^{k+1}, y, z^k)$$

$$z^{k+1} = z^k + t(Ax^{k+1} - y^{k+1})$$

- 对对偶问题(D)用近似点梯度法等价于对原问题(P)使用交替极小化方法

► 【例】 利用对偶近似点梯度法(16)求解

$$\min_x f(x) + \|Ax - b\| \quad \min_{x,y} f(x) + \|y\|, \quad \text{s.t. } Ax - b = y$$

- 设 f 是强凸函数, $\|\cdot\|$ 是任意一种范数. 令 $h(y) = \|y - b\|$, 则

$$h^*(z) = \begin{cases} b^T z & \|z\|_* \leq 1, \\ +\infty & \text{otherwise.} \end{cases} \quad \text{prox}_{th^*}(x) = \mathcal{P}_{\|z\|_* \leq 1}(x - tb).$$

应用对偶近似点梯度法(16), 更新如下:

$$x^{k+1} = \arg \min_x \left\{ f(x) + (A^T z^k)^T x \right\}, \quad z^{k+1} = \mathcal{P}_{\|z\|_* \leq 1}(z^k + t(Ax^{k+1} - b))$$

- 交替极小化方法:

$$x^{k+1} = \arg \min_x f(x) + \|y^k\| + (z^k)^T (Ax - b - y^k),$$

$$y^{k+1} = \arg \min_y f(x^{k+1}) + \|y\| + (z^k)^T (Ax^{k+1} - b - y) + \frac{t}{2} \|Ax^{k+1} - b - y\|_2^2,$$

$$z^{k+1} = z^k + t(Ax^{k+1} - b - y^{k+1})$$

$$L(x, y, z) = f(x) + \|y\| + z^T (Ax - b - y), \quad L_t(x, y, z) = L(x, y, z) + \frac{t}{2} \|Ax - b - y\|_2^2$$