

机器学习中的优化算法

Lecture09: 复合优化算法-交替方向乘子法

张立平

清华大学数学科学系

办公室：理科楼#A302, Tel: 62798531

E-mail: lipingzhang@tsinghua.edu.cn

Contents and Acknowledgement

- 教材：最优化：建模、算法与理论

<http://bicmr.pku.edu.cn/wenzw/bigdata2021.html>

- 致谢：北京大学文再文教授

Outline of ADMM

- 交替方向乘子法
- Douglas-Rachford Splitting算法
- 常用变形和技巧
- 应用举例
- ADMM收敛性分析

ADMM针对的典型问题

► 典型优化问题形式:

$$\begin{aligned} \min_{x_1, x_2} \quad & f_1(x_1) + f_2(x_2), \\ \text{s.t.} \quad & A_1 x_1 + A_2 x_2 = b. \end{aligned} \tag{1}$$

- f_1, f_2 是适当闭凸函数, 但不要求是光滑的, $x_1 \in \mathbb{R}^n, x_2 \in \mathbb{R}^m$, $A_1 \in \mathbb{R}^{p \times n}, A_2 \in \mathbb{R}^{p \times m}, b \in \mathbb{R}^p$.
- **问题特点:** 目标函数可以分成彼此分离的两块, 但是变量被线性约束结合在一起. 常见的一些无约束和带约束的优化问题都可以表示成这一形式.

【例】 可以分成两块 of 无约束优化问题:

$$\min_x f_1(x) + f_2(x) \iff \begin{cases} \min_{x, z} & f_1(x) + f_2(z) \\ \text{s.t.} & x - z = 0. \end{cases}$$

【例】带线性变换的无约束优化问题:

$$\min_x f_1(x) + f_2(Ax) \iff \begin{cases} \min_{x,z} f_1(x) + f_2(z) \\ \text{s.t. } Ax - z = 0. \end{cases}$$

【例】凸集 $C \subset \mathbb{R}^n$ 上的约束优化问题:

$$\begin{cases} \min_x f(x) \\ \text{s.t. } Ax \in C \end{cases} \iff \begin{cases} \min_{x,z} f(x) + I_C(z) \\ \text{s.t. } Ax - z = 0. \end{cases}$$

【例】全局一致性问题:

$$\min_x \sum_{i=1}^N \phi_i(x) \iff \begin{cases} \min_{x_i, z} \sum_{i=1}^N \phi_i(x_i) \\ \text{s.t. } x_i - z = 0, i = 1, 2, \dots, N. \end{cases}$$

交替方向乘子法ADMM

► 典型优化问题(1)的增广拉格朗日函数:

$$\begin{aligned} L_{\rho}(x_1, x_2, y) = & f_1(x_1) + f_2(x_2) + y^T(A_1x_1 + A_2x_2 - b) \\ & + \frac{\rho}{2}\|A_1x_1 + A_2x_2 - b\|_2^2. \end{aligned} \quad (2)$$

► ALM迭代:

$$(x_1^{k+1}, x_2^{k+1}) = \arg \min_{x_1, x_2} L_{\rho}(x_1, x_2, y^k), \quad (3)$$

$$y^{k+1} = y^k + \tau\rho(A_1x_1^{k+1} + A_2x_2^{k+1} - b). \quad (4)$$

► ADMM的基本思路: ALM中(3)同时对 x_1 和 x_2 进行优化有时候比较困难, 而固定一个变量求解关于另一个变量的极小问题可能比较简单, 因此我们可

以考虑对 x_1 和 x_2 交替求极小.

$$x_1^{k+1} = \arg \min_{x_1} L_\rho(x_1, x_2^k, y^k), \quad (5)$$

$$x_2^{k+1} = \arg \min_{x_2} L_\rho(x_1^{k+1}, x_2, y^k), \quad (6)$$

$$y^{k+1} = y^k + \tau \rho(A_1 x_1^{k+1} + A_2 x_2^{k+1} - b), \quad (7)$$

其中 τ 为步长, 通常取值于 $\left(0, \frac{1+\sqrt{5}}{2}\right]$.

► **ADMM的收敛准则:** 根据最优性条件, 若 x_1^*, x_2^* 为问题(1)的最优解, y^* 为对应的拉格朗日乘子, 则以下条件满足:

$$0 \in \partial_{x_1} L(x_1^*, x_2^*, y^*) = \partial f_1(x_1^*) + A_1^T y^*, \quad (8a)$$

$$0 \in \partial_{x_2} L(x_1^*, x_2^*, y^*) = \partial f_2(x_2^*) + A_2^T y^*, \quad (8b)$$

$$A_1 x_1^* + A_2 x_2^* = b, \quad (8c)$$

其中 $L(x_1, x_2, y) = f_1(x_1) + f_2(x_2) + y^T(A_1 x_1 + A_2 x_2 - b)$. 条件(8c)又称为原始可行性条件, 条件(8a)和条件(8b)又称为对偶可行性条件.

ADMM单步迭代最优性条件

- 由 x_2 的更新

$$x_2^k = \arg \min_x \left\{ f_2(x) + \frac{\rho}{2} \left\| A_1 x_1^k + A_2 x - b + \frac{y^{k-1}}{\rho} \right\|^2 \right\},$$

$$\implies 0 \in \partial f_2(x_2^k) + A_2^T [y^{k-1} + \rho(A_1 x_1^k + A_2 x_2^k - b)]. \quad (9)$$

当 $\tau = 1$ 时, 由(7)可知 $0 \in \partial f_2(x_2^k) + A_2^T y^k$.

- 由 x_1 的更新

$$x_1^k = \arg \min_x \left\{ f_1(x) + \frac{\rho}{2} \left\| A_1 x + A_2 x_2^{k-1} - b + \frac{y^{k-1}}{\rho} \right\|^2 \right\},$$

$$\implies 0 \in \partial f_1(x_1^k) + A_1^T [\rho(A_1 x_1^k + A_2 x_2^{k-1} - b) + y^{k-1}].$$

当 $\tau = 1$ 时, 由(7)可知

$$0 \in \partial f_1(x_1^k) + A_1^T (y^k + A_2(x_2^{k-1} - x_2^k)). \quad (10)$$

对比(10)和条件(8a)可知, 多出来的项为 $A_1^T A_2(x_2^{k-1} - x_2^k)$. 因此要检测对偶可行性只需要检测残差:

$$s^k = A_1^T A_2(x_2^{k-1} - x_2^k).$$

- 当 x_2 更新取到精确解且 $\tau = 1$ 时, 判断ADMM是否收敛只需要检测前述两个残差 r^k, s^k 是否充分小:

$$\begin{aligned} 0 &\approx \|r^k\| = \|A_1 x_1^k + A_2 x_2^k - b\| && \text{原始可行性,} \\ 0 &\approx \|s^k\| = \|A_1^T A_2(x_2^{k-1} - x_2^k)\| && \text{对偶可行性.} \end{aligned} \tag{11}$$

► 典型优化问题(1)的ADMM的收敛准则:

$$\begin{aligned} 0 &\approx \|r^k\| = \|A_1 x_1^k + A_2 x_2^k - b\| && \text{原始可行} \\ 0 &\approx \|s^k\| = \|A_1^T A_2(x_2^{k-1} - x_2^k)\| && \text{对偶可行} \end{aligned}$$

Douglas-Rachford Splitting (DRS) 算法

DRS算法是一类非常重要的算子分裂算法, 用于求解复合优化问题

$$\min \quad \psi(x) = f(x) + h(x)$$

其中 g, h 是闭凸函数. **DRS算法的迭代格式**是:

$$\begin{aligned}x^{k+1} &= \text{prox}_{th}(z^k) \\y^{k+1} &= \text{prox}_{tf}(2x^{k+1} - z^k) \\z^{k+1} &= z^k + y^{k+1} - x^{k+1}\end{aligned}\tag{12}$$

- 引入DRS算法的等价变形: 按 y, z, x 的顺序更新

$$\begin{aligned}y^{k+1} &= \text{prox}_{tf}(2x^k - z^k) \\z^{k+1} &= z^k + y^{k+1} - x^k \\x^{k+1} &= \text{prox}_{th}(z^{k+1})\end{aligned}$$

- 引入辅助变量 $w^k = z^k - x^k$, 消去 z^k, z^{k+1} 得等价的DRS算法的迭代格式:

$$\begin{aligned} y^{k+1} &= \text{prox}_{tf}(x^k - w^k) \\ x^{k+1} &= \text{prox}_{th}(w^k + y^{k+1}) \\ w^{k+1} &= w^k + y^{k+1} - x^{k+1} \end{aligned} \quad (13)$$

- DRS算法还可以写成关于 z^k 的不动点迭代: $z^{k+1} = T(z^k)$,

$$T(z) = z + \text{prox}_{tf}(2\text{prox}_{th}(z) - z) - \text{prox}_{th}(z).$$

- **优势:** 去掉变量 x^k, y^k ; 利用不动点迭代的收敛性、压缩算子; 可推广成加速算法; T 的不动点与 $\min \psi(x)$ 的最小值点密切相关.
- $z = T(z) \Rightarrow \text{prox}_{th}(z) \in \arg \min \psi(x)$
 令 $x = \text{prox}_{th}(z)$, 由 $z = T(z)$ 知, $\text{prox}_{tf}(2x - z) = x = \text{prox}_{th}(z)$
 $\Rightarrow x - z \in t\partial f(x), \quad z - x \in t\partial h(x) \Rightarrow \text{prox}_{th}(z) \in \arg \min \psi(x)$
- 设 $x \in \arg \min \psi(x)$, 则存在 $u \in t\partial f(x) \cap (-t\partial h(x))$ 使得 $x - u$ 是 T 的不动点.
 $u \in t\partial f(x) \cap (-t\partial h(x)) \Rightarrow x = \text{prox}_{tf}(x + u), \quad x = \text{prox}_{th}(x - u)$

► Douglas-Rachford 迭代映射

$$T(z) = z + \text{prox}_{tf}(2\text{prox}_{th}(z) - z) - \text{prox}_{th}(z)$$

$$G(z) = z - T(z) = \text{prox}_{th}(z) - \text{prox}_{tf}(2\text{prox}_{th}(z) - z)$$

- T 是固定非扩张的 (firmly non-expansive)

$$(T(x) - T(y))^T (x - y) \geq \|T(x) - T(y)\|^2.$$

- ① 令 $x = \text{prox}_{th}(z)$, $\hat{x} = \text{prox}_{th}(\hat{z})$, 则有

$$(x - \hat{x})^T (z - \hat{z}) \geq \|x - \hat{x}\|_2^2.$$

- ② 令 $y = \text{prox}_{tf}(2x - z)$, $\hat{y} = \text{prox}_{tf}(2\hat{x} - \hat{z})$, 则有

$$(2x - z - 2\hat{x} + \hat{z})^T (y - \hat{y}) \geq \|y - \hat{y}\|_2^2.$$

- ③ 令 $a = x - \hat{x}$, $b = y - \hat{y}$, $c = z - \hat{z}$, 则由 $T(z) = z + y - x$ 和 $T(\hat{z}) = \hat{z} + \hat{y} - \hat{x}$ 及①②知,

$$a^T c \geq \|a\|_2^2, \quad (2a - c)^T b \geq \|b\|_2^2, \quad T(z) - T(\hat{z}) = b + c - a.$$

于是,

$$\begin{aligned} & (T(z) - T(\hat{z}))^T (z - \hat{z}) \\ &= \|T(z) - T(\hat{z})\|_2^2 + (b + c - a)^T (a - b) \\ &= \|T(z) - T(\hat{z})\|_2^2 + (a^T c - \|a\|_2^2) + \left((2a - c)^T b - \|b\|_2^2 \right) \\ &\geq \|T(z) - T(\hat{z})\|_2^2. \end{aligned}$$

- G 也是固定非扩张的

$$\begin{aligned} & (G(z) - G(\hat{z}))^T (z - \hat{z}) \\ &= \|G(z) - G(\hat{z})\|_2^2 + (T(z) - T(\hat{z}))^T (z - \hat{z}) - \|T(z) - T(\hat{z})\|_2^2 \\ &\geq \|G(z) - G(\hat{z})\|_2^2 \end{aligned}$$

- 添加松弛项来加快收敛速度: $1 < \rho < 2$ 超松弛; $0 < \rho < 1$ 欠松弛

$$z^{k+1} = z^k + \rho(T(z^k) - z^k)$$

- DRS的松弛形式1:

$$\begin{cases} x^{k+1} = \text{prox}_{th}(z^k) \\ y^{k+1} = \text{prox}_{tf}(2x^{k+1} - z^k) \\ z^{k+1} = z^k + \rho(y^{k+1} - x^{k+1}) \end{cases}$$

- DRS的松弛形式2:

$$\begin{cases} y^{k+1} = \text{prox}_{tf}(x^k - w^k) \\ x^{k+1} = \text{prox}_{th}((1 - \rho)x^k + \rho y^{k+1} + w^k) \\ w^{k+1} = w^k + \rho y^{k+1} + (1 - \rho)x^k - x^{k+1} \end{cases}$$

DRS与ADMM的关系

$$(P) \quad \min f_1(x_1) + f_2(x_2) \quad \text{s.t.} \quad A_1x_1 + A_2x_2 = b$$

$$(D) \quad \max -b^T z - f_1^*(-A_1^T z) - f_2^*(-A_2^T z) \quad \Leftrightarrow$$

$$\min \underbrace{b^T z + f_1^*(-A_1^T z)}_{f(z)} + \underbrace{f_2^*(-A_2^T z)}_{h(z)}$$

► 对(P)用ADMM等价于对(D)用DRS

Theorem 1. 令 $w^1 = -tA_2x_2^0$, 则对(D)用DRS算法(13)等价于对(P)用ADMM.

- 由 $y^{k+1} = \text{prox}_{tf}(x^k - w^k)$ 知

$$0 \in tb - tA_1 \partial f_1^*(-A_1^T y^{k+1}) - x^k + w^k + y^{k+1},$$

故存在 $x_1^k \in \partial f_1^*(-A_1^T y^{k+1})$, 使得

$$y^{k+1} = x^k - w^k + t(A_1x_1^k - b), \quad (14)$$

因此,

$$x_1^k = \arg \min_{x_1} \left\{ f_1(x_1) + (x^k)^T (A_1 x_1 - b) + \frac{t}{2} \|A_1 x_1 - b - w^k/t\|_2^2 \right\}.$$

- 由 $x^{k+1} = \text{prox}_{th}(w^k + y^{k+1})$ 知

$$0 \in tA_2 \partial f_2^*(-A_2^T x^{k+1}) + w^k + y^{k+1} - x^{k+1},$$

故存在 $x_2^k \in \partial f_2^*(-A_2^T x^{k+1})$ 使得

$$x^{k+1} = x^k + t(A_1 x_1^k + A_2 x_2^k - b), \quad (15)$$

于是

$$x_2^k = \arg \min_{x_2} \left\{ f_2(x_2) + (x^k)^T (A_2 x_2) + \frac{t}{2} \|A_1 x_1^k + A_2 x_2 - b\|_2^2 \right\}.$$

- 由 $w^{k+1} = w^k + y^{k+1} - x^{k+1}$ 及(14)和(15)知 $w^{k+1} = -tA_2 x_2^k$.
- 定义(P)的增广拉格朗日函数

$$L_t(x_1, x_2, z) = f_1(x_1) + f_2(x_2) + z^T (A_1 x_1 + A_2 x_2 - b) + \frac{t}{2} \|A_1 x_1 + A_2 x_2 - b\|_2^2$$

令 $z^k = x^{k+1}$, 则有

$$\begin{aligned}x_1^k &= \arg \min_{x_1} L_t(x_1, x_2^{(k-1)}, z^{(k-1)}) \\&= \arg \min_{x_1} \left(f_1(x_1) + (z^{k-1})^T A_1 x_1 + \frac{t}{2} \|A_1 x_1 + A_2 x_2^{k-1} - b\|_2^2 \right) \\x_2^k &= \arg \min_{x_2} L_t(x_1^k, x_2, z^{k-1}) \\&= \arg \min_{x_2} \left(f_2(x_2) + (z^{k-1})^T A_2 x_2 + \frac{t}{2} \|A_1 x_1^k + A_2 x_2 - b\|_2^2 \right) \\z^k &= z^{k-1} + t(A_1 x_1^k + A_2 x_2^k - b)\end{aligned}$$

ADMM中的常用技巧: 线性化

► 线性化技巧使用近似点项对子问题目标函数进行二次近似, 使得子问题有显式解.

- 考虑子问题(5):

$$\min_{x_1} f_1(x_1) + \frac{\rho}{2} \|A_1 x_1 - v^k\|^2, \quad v^k = b - A_2 x_2^k - \frac{1}{\rho} y^k. \quad (16)$$

- 当子问题目标函数可微时, 线性化将问题(16)变为

$$x_1^{k+1} = \arg \min_{x_1} \left\{ \left(\nabla f_1(x_1^k) + \rho A_1^T (A_1 x_1^k - v^k) \right)^T x_1 + \frac{1}{2\eta_k} \|x_1 - x_1^k\|_2^2 \right\},$$

其中 η_k 是步长参数. 这等价于做一步梯度下降.

- 当目标函数不可微时, 可以考虑只将二次项线性化:

$$x_1^{k+1} = \arg \min_{x_1} \left\{ f_1(x_1) + \rho \left(A_1^T (A_1 x_1^k - v^k) \right)^T x_1 + \frac{1}{2\eta_k} \|x_1 - x_1^k\|_2^2 \right\}.$$

这等价于做一步近似点梯度步. 若 $f_1(x_1)$ 是可微函数与不可微函数的和时, 将可微部分线性化.

ADMM中的常用技巧: 缓存分解

► 缓存分解

- 如果目标函数中含二次函数, 例如 $f_1(x_1) = \frac{1}{2} \|C x_1 - d\|_2^2$, 那么针对 x_1 的更新(5)等价于求解线性方程组

$$(C^T C + \rho A_1^T A_1) x_1 = C^T d + \rho A_1^T v^k.$$

- 虽然子问题有显式解, 但是每步求解的复杂度仍然比较高, 这时候可以考虑用缓存分解的方法. 首先对 $C^T C + \rho A_1^T A_1$ 进行Cholesky 分解并缓存分解的结果, 在每步迭代中只需要求解简单的三角形方程组.
- 当 ρ 发生更新时, 就要重新进行分解. 特别地, 当 $C^T C + \rho A_1^T A_1$ 具有特殊结构(一部分容易求逆, 另一部分是低秩的情形)时, 可以用SMW公式来求逆. $(A + BC)^{-1} = A^{-1} - A^{-1} B (I + CA^{-1} B)^{-1} C A^{-1}$

ADMM中的常用技巧: 优化转移

► **优化转移**就是为了方便求解子问题, 可以用一个性质好的矩阵 D 近似二次项 $A_1^T A_1$, 此时子问题(16)替换为

$$x_1^{k+1} = \arg \min_{x_1} \left\{ f_1(x_1) + \frac{\rho}{2} \|A_1 x_1 - v^k\|_2^2 + \frac{\rho}{2} (x_1 - x^k)^T (D - A_1^T A_1) (x_1 - x^k) \right\}.$$

- 通过选取合适的 D , 当计算

$$\arg \min_{x_1} \left\{ f_1(x_1) + \frac{\rho}{2} x_1^T D x_1 \right\}$$

明显比计算

$$\arg \min_{x_1} \left\{ f_1(x_1) + \frac{\rho}{2} x_1^T A_1^T A_1 x_1 \right\}$$

要容易时, **优化转移**可以极大地简化子问题的计算. 特别地, 当 $D = \frac{\eta_k}{\rho} I$ 时, 优化转移等价于做单步的近似点梯度步.

ADMM中的常用技巧: 二次罚项系数的动态调节

► **动态调节二次罚项系数**在交替方向乘子法的实际应用中是一个非常重要的数值技巧.

- 由(11)知, 求解过程中二次罚项系数 ρ 太大会导致原始可行性 $\|r^k\|$ 下降很快, 但是对偶可行性 $\|s^k\|$ 下降很慢; 二次罚项系数太小, 则效果相反. 这都会导致收敛比较慢或得到的解的可行性很差. 一个自然的想法是在每次迭代时动态调节惩罚系数 ρ 的大小, 从而使得原始可行性和对偶可行性能够以比较一致的速度下降到零.
- 简单有效的动态调节二次罚项系数的方式:

$$\rho^{k+1} = \begin{cases} \gamma_p \rho^k, & \|r^k\| > \mu \|s^k\|, \\ \rho^k / \gamma_d & \|s^k\| > \mu \|r^k\|, \\ \rho^k, & \text{otherwise,} \end{cases}$$

其中 $\mu > 1, \gamma_p > 1, \gamma_d > 1$ 是参数, 常见的选择为 $\mu = 10, \gamma_p = \gamma_d = 2$. 在迭代过程中将原始可行性 $\|r^k\|$ 和对偶可行性 $\|s^k\|$ 保持在彼此的 μ 倍内.

选择合适的惩罚项 $\|\cdot\|_P$ ($P = F^T F$)

ADMM中的常用技巧: 超松弛

考虑求解优化问题(1)的ADMM迭代格式:

$$x_1^{k+1} = \arg \min_{x_1} L_\rho(x_1, x_2^k, y^k), \quad (17)$$

$$x_2^{k+1} = \arg \min_{x_2} L_\rho(x_1^{k+1}, x_2, y^k), \quad (18)$$

$$y^{k+1} = y^k + \tau \rho(A_1 x_1^{k+1} + A_2 x_2^{k+1} - b). \quad (19)$$

- 在(18)与(19)中, $A_1 x_1^{k+1}$ 可以被替换为

$$\alpha_k A_1 x_1^{k+1} + (1 - \alpha_k)(A_2 x_2^k - b),$$

其中 $\alpha_k \in (0, 2)$ 是一个松弛参数.

- 当 $\alpha_k > 1$ 时, 这种技巧称为超松弛. 当 $\alpha_k < 1$ 时, 这种技巧称为欠松弛. 实验表明 $\alpha_k \in [1.5, 1.8]$ 的超松弛可以提高收敛速度.

ADMM应用

■ LASSO 问题 (合适的拆分: $x = z$)

$$\min \mu \|x\|_1 + \frac{1}{2} \|Ax - b\|^2 \iff \begin{cases} \min_{x,z} \frac{1}{2} \|Ax - b\|^2 + \mu \|z\|_1, \\ \text{s.t. } x = z. \end{cases}$$

► 交替方向乘子法迭代格式为

$$\begin{aligned} x^{k+1} &= \arg \min_x \left\{ \frac{1}{2} \|Ax - b\|^2 + \frac{\rho}{2} \|x - z^k + y^k / \rho\|_2^2 \right\}, \\ &= (A^T A + \rho I)^{-1} (A^T b + \rho z^k - y^k), \\ z^{k+1} &= \arg \min_z \left\{ \mu \|z\|_1 + \frac{\rho}{2} \|x^{k+1} - z + y^k / \rho\|^2 \right\}, \\ &= \text{prox}_{(\mu/\rho)\|\cdot\|_1} \left(x^{k+1} + y^k / \rho \right), \\ y^{k+1} &= y^k + \tau \rho (x^{k+1} - z^{k+1}). \end{aligned}$$

- 因为 $\rho > 0$, 所以 $A^T A + \rho I$ 总是可逆的. x 迭代本质上是计算一个岭回归问题(ℓ_2 范数平方正则化的最小二乘问题). 而对 z 的更新为 ℓ_1 范数的邻近算子, 同样有显式解. 在求解 x 迭代时, 若使用固定的罚因子 ρ , 我们可以缓存矩阵 $A^T A + \rho I$ 的初始分解, 从而减小后续迭代中的计算量.
- 在LASSO 问题中, 矩阵 $A \in \mathbb{R}^{m \times n}$ 通常有较多的列 $m \ll n$, 因此 $A^T A \in \mathbb{R}^{n \times n}$ 是一个低秩矩阵, 二次罚项的作用就是将 $A^T A$ 增加了一个正定项. 该ADMM 主要运算量来自更新 x 变量时求解线性方程组, 复杂度为 $O(n^3)$. 若使用缓存分解技术或SMW 公式:

$$(A^T A + \rho I_n)^{-1} = \frac{1}{\rho} \left[I_n - A^T (A A^T + \rho I_m)^{-1} A \right],$$

则可进一步降低每次迭代的运算量, 复杂度为 $O(m^3)$.

■ 考虑LASSO 问题的对偶问题:

$$\begin{aligned} \min \quad & b^T y + \frac{1}{2} \|y\|^2, \\ \text{s.t.} \quad & \|A^T y\|_\infty \leq \mu. \end{aligned} \quad (20)$$

- 引入约束 $A^T y + z = 0$, 则

$$(20) \iff \begin{cases} \min & \underbrace{b^T y + \frac{1}{2} \|y\|^2}_{f(y)} + \underbrace{I_{\|z\|_\infty \leq \mu}(z)}_{h(z)}, \\ \text{s.t.} & A^T y + z = 0. \end{cases} \quad (21)$$

- 对偶问题(21)的增广拉格朗日函数为

$$L_\rho(y, z, x) = b^T y + \frac{1}{2} \|y\|^2 + I_{\|z\|_\infty \leq \mu}(z) - x^T (A^T y + z) + \frac{\rho}{2} \|A^T y + z\|^2.$$

- 当固定 y, x 时, 对 z 的更新即向无穷范数球 $\{z \mid \|z\|_\infty \leq \mu\}$ 做欧几里得投影, 将每个分量截断在区间 $[-\mu, \mu]$ 中. 当固定 z, x 时, 对 y 的更新即求解线性方程组

$$(I + \rho A A^T) y = A(x^k - \rho z^{k+1}) - b. \quad (22)$$

► LASSO 问题的对偶问题(21)的ADMM 迭代格式为

$$\begin{aligned} z^{k+1} &= \mathcal{P}_{\|z\|_\infty \leq \mu} \left(x^k / \rho - A^T y^k \right), \\ y^{k+1} &= (I + \rho A A^T)^{-1} \left(A(x^k - \rho z^{k+1}) - b \right), \\ x^{k+1} &= x^k - \tau \rho (A^T y^{k+1} + z^{k+1}). \end{aligned}$$

- 虽然ADMM 应用于对偶问题也需要求解一个线性方程组(22), 但由于LASSO 问题的特殊性 $m \ll n$, 求解 y 更新的线性方程组(22)需要的计算量是 $O(m^3)$, 使用缓存分解技巧后可进一步降低至 $O(m^2)$, 这大大小于针对原始问题的ADMM.

► $m = 512; n = 1024; A = \text{randn}(m, n); u = \text{sprandn}(n, 1, r); b = A * u;$
取 $\mu = 10^{-3}$, 用ADMM求解LASSO原问题和对偶问题: 取 $\tau = 1.618$, 原问题和对偶问题分别取 $\rho = 0.01, 100$.

终止条件设为: $|f(x^k) - f(x^{k-1})| < 10^{-8}$ 和最大迭代次数2000. 对原问题还添加终止条件 $\|x^k - z^k\| < 10^{-10}$; 对对偶问题 $\|A^T y^k + z^k\| < 10^{-10}$.




Figure 1: ADMM 求解LASSO 问题: 原问题所需迭代次数少, 对偶问题每一次迭代所需时间短.

■ **广义LASSO 问题**指 x 本身不稀疏,但在某种变换下是稀疏的:

$$\min_x \quad \mu \|Fx\|_1 + \frac{1}{2} \|Ax - b\|^2. \quad (23)$$

- 当 $F \in \mathbb{R}^{(n-1) \times n}$ 是**一阶**差分矩阵

$$F_{ij} = \begin{cases} 1, & j = i + 1, \\ -1, & j = i, \\ 0, & \text{otherwise,} \end{cases}$$

且 $A = I$ 时, 广义LASSO问题(23)为图像去噪问题的**TV 模型**:

$$\min_x \quad \frac{1}{2} \|x - b\|^2 + \mu \sum_{i=1}^{n-1} |x_{i+1} - x_i|.$$

当 $A = I$ 且 F 是二阶差分矩阵时, 问题(23)被称为**一范数趋势滤波**.

► 广义LASSO问题(23)等价于

$$\begin{aligned} \min_{x, z} \quad & \frac{1}{2} \|Ax - b\|^2 + \mu \|z\|_1 \\ \text{s.t.} \quad & Fx - z = 0, \end{aligned} \quad (24)$$

► 对广义LASSO问题(24)的ADMM迭代为

$$x^{k+1} = (A^T A + \rho F^T F)^{-1} \left(A^T b + \rho F^T \left(z^k - \frac{y^k}{\rho} \right) \right),$$

$$z^{k+1} = \text{prox}_{(\mu/\rho)\|\cdot\|_1} \left(F x^{k+1} + \frac{y^k}{\rho} \right),$$

$$y^{k+1} = y^k + \tau \rho (F x^{k+1} - z^{k+1}).$$

► 注: 对于全变差去噪问题, $A^T A + \rho F^T F$ 是三对角矩阵, 此时 x 迭代可以在 $\mathcal{O}(n)$ 的时间复杂度内解决; 对于图像去模糊问题, A 是卷积算子, 则利用傅里叶变换可将求解方程组的复杂度降低至 $\mathcal{O}(n \log n)$; 对于一范数趋势滤波问题, $A^T A + \rho F^T F$ 是五对角矩阵, 所以 x 迭代仍可以在 $\mathcal{O}(n)$ 的时间复杂度内解决. GOLUB GH, VAN LOAN CF, *Matrix computations* 2012

■ 稀疏逆协方差矩阵估计问题:

$$\min_X \langle S, X \rangle - \ln \det X + \mu \|X\|_1, \quad (25)$$

其中 S 是已知的对称矩阵, 通常由样本协方差矩阵得到. 变量 $X \in \mathcal{S}_{++}^n$, $\|\cdot\|_1$ 定义为矩阵所有元素绝对值的和.

- (25)的目标函数由光滑项和非光滑项组成, 将问题的两部分分离:

$$\begin{aligned} \min \quad & \underbrace{\langle S, X \rangle - \ln \det X}_{f(X)} + \underbrace{\mu \|Z\|_1}_{h(Z)}, \\ \text{s.t.} \quad & X = Z. \end{aligned}$$

- 其增广拉格朗日函数为

$$L_\rho(X, Z, U) = \langle S, X \rangle - \ln \det X + \mu \|Z\|_1 + \langle U, X - Z \rangle + \frac{\rho}{2} \|X - Z\|_F^2.$$

► ADMM迭代:

- 对 X 的更新, 固定 Z^k, U^k , 关于 X 的子问题是凸的, 故由最优性条件

$$\begin{aligned} S - X^{-1} + U^k + \rho(X - Z^k) &= 0, \\ \implies X^{k+1} &= Q \text{Diag}(x_1, x_2, \dots, x_n) Q^T, \end{aligned}$$

其中 Q 包含矩阵 $S - \rho Z^k + U^k$ 的所有特征向量, x_i 的表达式为

$$x_i = \frac{-d_i + \sqrt{d_i^2 + 4\rho}}{2\rho},$$

d_i 为矩阵 $S - \rho Z^k + U^k$ 的第 i 个特征值.

- 对 Z 的更新, 固定 X^{k+1}, U^k , 关于 Z 的更新为矩阵 ℓ_1 范数的邻近算子.
- 乘子更新: $U^{k+1} = U^k + \tau\rho(X^{k+1} - Z^{k+1})$.

■ 矩阵分离问题:

$$\begin{aligned} \min_{X, S} \quad & \|X\|_* + \mu\|S\|_1 \\ \text{s.t.} \quad & X + S = M, \end{aligned} \tag{26}$$

其中 $\|\cdot\|_1$ 与 $\|\cdot\|_*$ 分别表示矩阵 ℓ_1 范数与核范数.

- 问题(26)的增广拉格朗日函数

$$L_\rho(X, S, Y) = \|X\|_* + \mu\|S\|_1 + \langle Y, X + S - M \rangle + \frac{\rho}{2}\|X + S - M\|_F^2.$$

- 对 X 的更新

$$\begin{aligned} X^{k+1} &= \arg \min_X L_\rho(X, S^k, Y^k) \\ &= \arg \min_X \left\{ \|X\|_* + \frac{\rho}{2} \left\| X + S^k - M + \frac{Y^k}{\rho} \right\|_F^2 \right\} \\ &= \arg \min_X \left\{ \frac{1}{\rho} \|X\|_* + \frac{1}{2} \left\| X + S^k - M + \frac{Y^k}{\rho} \right\|_F^2 \right\} \\ &= U \text{Diag} \left(\text{prox}_{(1/\rho)\|\cdot\|_1}(\sigma(A)) \right) V^T, \end{aligned}$$

其中 $A = M - S^k - \frac{Y^k}{\rho}$, $\sigma(A)$ 为 A 的所有非零奇异值构成的向量并且 $U \text{Diag}(\sigma(A)) V^T$ 为 A 的奇异值分解.

- 对 S 的更新

$$\begin{aligned} S^{k+1} &= \arg \min_S L_\rho(X^{k+1}, S, Y^k) \\ &= \arg \min_S \left\{ \mu \|S\|_1 + \frac{\rho}{2} \left\| X^{k+1} + S - M + \frac{Y^k}{\rho} \right\|_F^2 \right\} \\ &= \text{prox}_{(\mu/\rho)\|\cdot\|_1} \left(M - X^{k+1} - \frac{Y^k}{\rho} \right). \end{aligned}$$

► 矩阵分离问题(26)的ADMM迭代:

$$\begin{aligned} X^{k+1} &= U \text{Diag} \left(\text{prox}_{(1/\rho)\|\cdot\|_1} (\sigma(A)) \right) V^T, \\ S^{k+1} &= \text{prox}_{(\mu/\rho)\|\cdot\|_1} \left(M - L^{k+1} - \frac{Y^k}{\rho} \right), \\ Y^{k+1} &= Y^k + \tau \rho (X^{k+1} + S^{k+1} - M). \end{aligned}$$

■ 全局一致性优化问题:

$$\min_{x_i, z} \sum_{i=1}^N \phi_i(x_i) \quad \text{s.t.} \quad x_i - z = 0, \quad i = 1, 2, \dots, N.$$

● 增广拉格朗日函数

$$L_\rho(x_1, \dots, x_N, z, y_1, \dots, y_N) = \sum_{i=1}^N \phi_i(x_i) + \sum_{i=1}^N y_i^\top (x_i - z) + \frac{\rho}{2} \sum_{i=1}^N \|x_i - z\|^2.$$

注: 虽然表面上看增广拉格朗日函数有 $(N + 1)$ 个变量块, 但本质上还是两个变量块. 这是因为在更新某个 x_i 时并没有利用其他 x_i , 所有 x_i 可以看成是一个整体. 相应地, 所有乘子 y_i 也可以看成是一个整体.

► 全局一致性优化问题的ADMM迭代:

$$x_i^{k+1} = \text{prox}_{\phi_i/\rho} \left(z^k - y_i^k / \rho \right), \quad i = 1, 2, \dots, N,$$

$$z^{k+1} = \frac{1}{N} \sum_{i=1}^N \left(x_i^{k+1} + y_i^k / \rho \right),$$

$$y_i^{k+1} = y_i^k + \tau \rho (x_i^{k+1} - z^{k+1}), \quad i = 1, 2, \dots, N.$$

■ 混合全变差和 ℓ_1 正则 $\min_x \mathbf{TV}(x) + \alpha \|Wx\|_1, \text{ s.t. } \|Rx - b\|_2 \leq \sigma$

- 新模型:

$$\begin{aligned} \min_x \quad & \sum_{i=1}^N \|z_i\|_2 + \alpha \|Wx\|_1 + \mathcal{I}(\|y\|_2 \leq \sigma) \\ \text{s.t.} \quad & z_i = D_i x, \forall i = 1, \dots, N \\ & y = Rx - b. \end{aligned}$$

- 将变量分为两块: x 和 $(y, \{z_i\})$, 约束化成:

$$\begin{pmatrix} R \\ D_1 \\ \vdots \\ D_N \end{pmatrix} x - \begin{pmatrix} y \\ z_1 \\ \vdots \\ z_N \end{pmatrix} = \begin{pmatrix} b \\ 0 \\ \vdots \\ 0 \end{pmatrix}.$$

- x 的子问题不易求解, 使用线性化二次项技巧简化proximal算子, 进行非精确更新

非凸约束优化问题的ADMM

考虑如下约束优化问题:

$$\begin{array}{ll} \min_{\mathbf{x}} & f(\mathbf{x}) \\ \text{s.t.} & \mathbf{x} \in \mathcal{S} \end{array} \Leftrightarrow \begin{array}{ll} \min_{\mathbf{x}} & f(\mathbf{x}) + \mathbb{I}_{\mathcal{S}}(\mathbf{z}) \\ \text{s.t.} & \mathbf{x} - \mathbf{z} = \mathbf{0} \end{array}$$

其中 f 是闭凸函数, \mathcal{S} 是非凸集合. 其交替方向乘子法迭代格式:

$$\begin{cases} \mathbf{x}^{k+1} = \arg \min_{\mathbf{x}} \left(f(\mathbf{x}) + \frac{\rho}{2} \|\mathbf{x} - \mathbf{z}^k + \mathbf{u}^k\|_2^2 \right), \\ \mathbf{z}^{k+1} = \mathcal{P}_{\mathcal{S}}(\mathbf{x}^{k+1} + \mathbf{u}^k), \quad \mathcal{P}_{\mathcal{S}}(\mathbf{z}) \text{ 是将 } \mathbf{z} \text{ 投影到集合 } \mathcal{S}, \text{ 难!} \\ \mathbf{u}^{k+1} = \mathbf{u}^k + \tau \rho (\mathbf{x}^{k+1} - \mathbf{z}^{k+1}). \end{cases}$$

► 特殊非凸集合 \mathcal{S}

- 基数: $\mathcal{S} = \{\mathbf{x} \mid \|\mathbf{x}\|_0 \leq c\}$, 计算向量 \mathbf{v} 到 \mathcal{S} 中的投影就是保留 \mathbf{v} 分量中绝对值从大到小排列的前 c 个, 其余分量变成0. 假设 \mathbf{v} 的各个分量满

足 $|v_{i_1}| \geq |v_{i_2}| \geq \cdots \geq |v_{i_n}|$, 则投影算子

$$(\mathcal{P}_{\mathcal{S}}(\mathbf{v}))_i = \begin{cases} v_i, & i \in \{i_1, \dots, i_c\}, \\ 0, & \text{otherwise.} \end{cases}$$

- 低秩投影: $\mathcal{S} = \{X \in \mathbb{R}^{m \times n} | \text{rank}(X) \leq r\}$, 计算矩阵 X 到 \mathcal{S} 中的投影就是对 X 做截断奇异值分解. 设 X 的奇异值分解为

$$X = \sum_i^{\min\{m,n\}} \sigma_i \mathbf{u}_i \mathbf{v}_i^T,$$

其中 $\sigma_1 \geq \sigma_2 \geq \cdots \geq \sigma_{\min\{m,n\}}$ 为奇异值, $\mathbf{u}_i, \mathbf{v}_i$ 为对应的左右奇异向量, 则投影算子

$$\mathcal{P}_{\mathcal{S}}(X) = \sum_{i=1}^r \sigma_i \mathbf{u}_i \mathbf{v}_i^T.$$

- 布尔约束: $\mathcal{S} = \{\mathbf{x} | x_i \in \{0, 1\}\}$, 则 $\mathcal{P}_{\mathcal{S}}(\mathbf{v})$ 就是把每个分量 v_i 变为0和1 中离它更近的数.

■ **非负矩阵分解和补全:** 已知一个非负矩阵的部分元素,求其非负分解. 它可以看作非负矩阵分解问题和低秩矩阵补全问题的结合, 是一个非常重要的统计学习方法.

- 已知从一个非负、秩为 r 的矩阵 $M \in \mathbb{R}^{m \times n}$ 中采样的部分元素 M_{ij} , $(i, j) \in \Omega \subset \{1, 2, \dots, m\} \times \{1, 2, \dots, n\}$, 目标是要找到非负矩阵 $X \in \mathbb{R}^{m \times p}$, $Y \in \mathbb{R}^{p \times n}$ 使得 $\|M - XY\|_F^2$ 极小. 则非负矩阵分解和补全问题:

$$\begin{aligned} \min_{X, Y} \quad & \|P \odot (XY - M)\|_F^2 \\ \text{s.t.} \quad & X \geq 0, Y \geq 0. \end{aligned} \quad P_{ij} = \begin{cases} 1, & (i, j) \in \Omega, \\ 0, & \text{otherwise.} \end{cases}$$

这个问题是非凸的.

- 为了利用交替方向乘子法的优势, 考虑其等价形式:

$$\begin{aligned} \min_{X,Y,Z,U,V} \quad & \frac{1}{2} \|XY - Z\|_F^2 \\ \text{s.t.} \quad & X = U, \quad Y = V, \\ & U \geq 0, \quad V \geq 0, \\ & P \odot (Z - M) = 0. \end{aligned}$$

- 增广拉格朗日函数

$$\begin{aligned} L_{\alpha,\beta}(X, Y, Z, U, V, \Lambda, \Pi) = & \frac{1}{2} \|XY - Z\|_F^2 + \langle \Lambda, X - U \rangle + \langle \Pi, Y - V \rangle \\ & + \frac{\alpha}{2} \|X - U\|_F^2 + \frac{\beta}{2} \|Y - V\|_F^2. \end{aligned}$$

- 交替方向乘子法

$$X^{k+1} = \arg \min_X L_{\alpha, \beta}(X, Y^k, Z^k, U^k, V^k, \Lambda^k, \Pi^k),$$

$$Y^{k+1} = \arg \min_Y L_{\alpha, \beta}(X^{k+1}, Y, Z^k, U^k, V^k, \Lambda^k, \Pi^k),$$

$$Z^{k+1} = \arg \min_{P \odot (Z - M) = 0} L_{\alpha, \beta}(X^{k+1}, Y^{k+1}, Z, U^k, V^k, \Lambda^k, \Pi^k),$$

$$U^{k+1} = \arg \min_{U \geq 0} L_{\alpha, \beta}(X^{k+1}, Y^{k+1}, Z^{k+1}, U, V^k, \Lambda^k, \Pi^k),$$

$$V^{k+1} = \arg \min_{V \geq 0} L_{\alpha, \beta}(X^{k+1}, Y^{k+1}, Z^{k+1}, U^{k+1}, V, \Lambda^k, \Pi^k),$$

$$\Lambda^{k+1} = \Lambda^k + \tau \alpha (X^{k+1} - U^{k+1}),$$

$$\Pi^{k+1} = \Pi^k + \tau \beta (Y^{k+1} - V^{k+1}).$$

求解可得

$$\begin{aligned}X^{k+1} &= \left(Z^k (Y^k)^T + \alpha U^k - \Lambda^k \right) \left(Y^k (Y^k)^T + \alpha I \right)^{-1} \\Y^{k+1} &= \left(X^{k+1} (X^{k+1})^T + \beta I \right)^{-1} \left((X^{k+1})^T Z^k + \beta V^k - \Pi^k \right) \\Z^{k+1} &= X^{k+1} Y^{k+1} + P \odot (M - X^{k+1} Y^{k+1}) \\U^{k+1} &= \mathcal{P}_+ \left(X^{k+1} + \frac{\Lambda^k}{\alpha} \right) \\V^{k+1} &= \mathcal{P}_+ \left(Y^{k+1} + \frac{\Pi^k}{\beta} \right) \\\Lambda^{k+1} &= \Lambda^k + \tau \alpha (X^{k+1} - U^{k+1}), \\\Pi^{k+1} &= \Pi^k + \tau \beta (Y^{k+1} - V^{k+1}).\end{aligned}$$

ADMM收敛性分析

► **必要假设:** 问题(1)的解集非空, $f_1(x), f_2(x)$ 均为闭凸函数, 且每个ADMM迭代子问题存在唯一解.

► **记号:** 由(1)的解集非空可设 (x_1^*, x_2^*, y^*) 是KKT 对

$$-A_1^T y^* \in \partial f_1(x_1^*), \quad -A_2^T y^* \in \partial f_2(x_2^*), \quad A_1 x_1^* + A_2 x_2^* = b. \quad (27)$$

目的是证明ADMM 迭代序列 $\{(x_1^k, x_2^k, y^k)\}$ 收敛到问题(1)的一个KKT 对, 于是定义

$$(e_1^k, e_2^k, e_y^k) \stackrel{\text{def}}{=} (x_1^k, x_2^k, y^k) - (x_1^*, x_2^*, y^*),$$

和

$$\begin{aligned} u^k &= -A_1^T [y^k + (1 - \tau)\rho(A_1 e_1^k + A_2 e_2^k) + \rho A_2 (x_2^{k-1} - x_2^k)], \\ v^k &= -A_2^T [y^k + (1 - \tau)\rho(A_1 e_1^k + A_2 e_2^k)], \\ \Psi_k &= \frac{1}{\tau\rho} \|e_y^k\|^2 + \rho \|A_2 e_2^k\|^2, \\ \Phi_k &= \Psi_k + \max(1 - \tau, 1 - \tau^{-1}) \rho \|A_1 e_1^k + A_2 e_2^k\|^2. \end{aligned} \quad (28)$$

Lemma 1. 假设 $\{(x_1^k, x_2^k, y^k)\}$ 为ADMM(5)-(7)产生一个迭代序列, 则对任意的 $k \geq 1$ 有

$$u^k \in \partial f_1(x_1^k), \quad v^k \in \partial f_2(x_2^k), \quad (29)$$

和

$$\begin{aligned} \Phi_k - \Phi_{k+1} \geq & \min(\tau, 1 + \tau - \tau^2) \rho \|A_2(x_2^k - x_2^{k+1})\|^2 \\ & + \min(1, 1 + \tau^{-1} - \tau) \rho \|A_1 e_1^{k+1} + A_2 e_2^{k+1}\|^2. \end{aligned} \quad (30)$$

注: 只有当 $\tau \in \left(0, \frac{1 + \sqrt{5}}{2}\right)$ 时, (30) 中不等号右侧的项才为非负.

Proof. 先证(29). 对 x_1^{k+1} , 由(5)知,

$$0 \in \partial f_1(x_1^{k+1}) + A_1^T y^k + \rho A_1^T (A_1 x_1^{k+1} + A_2 x_2^k - b).$$

将 $y^k = y^{k+1} - \tau \rho (A_1 x_1^{k+1} + A_2 x_2^{k+1} - b)$ 代入上式,

$$-A_1^T \left(y^{k+1} + (1 - \tau) \rho (A_1 x_1^{k+1} + A_2 x_2^{k+1} - b) + \rho A_2 (x_2^k - x_2^{k+1}) \right) \in \partial f_1(x_1^{k+1}).$$

根据 u^k 的定义和 $b = A_1 x_1^* + A_2 x_2^*$, $u^k \in \partial f_1(x_1^k)$. 对 x_2^{k+1} , 由(6)知

$$0 \in \partial f_2(x_2^{k+1}) + A_2^T y^k + \rho A_2^T (A_1 x_1^{k+1} + A_2 x_2^{k+1} - b),$$

又由(7)知

$$-A_2^T \left(y^{k+1} + (1 - \tau) \rho (A_1 x_1^{k+1} + A_2 x_2^{k+1} - b) \right) \in \partial f_2(x_2^{k+1}).$$

根据 v^k 的定义和 $b = A_1 x_1^* + A_2 x_2^*$, $v^k \in \partial f_2(x_2^k)$. 故(29)得证.

现证(30). 根据(27)和(29),

$$u^{k+1} \in \partial f_1(x_1^{k+1}), \quad -A_1^T y^* \in \partial f_1(x_1^*),$$

$$v^{k+1} \in \partial f_2(x_2^{k+1}), \quad -A_2^T y^* \in \partial f_2(x_2^*).$$

根据 f_1, f_2 凸,

$$\left\langle u^{k+1} + A_1^T y^*, x_1^{k+1} - x_1^* \right\rangle \geq 0,$$

$$\left\langle v^{k+1} + A_2^T y^*, x_2^{k+1} - x_2^* \right\rangle \geq 0.$$

再结合 u^{k+1}, v^{k+1} 的定义, 并注意到恒等式

$$A_1 x_1^{k+1} + A_2 x_2^{k+1} - b = (\tau \rho)^{-1} (y^{k+1} - y^k) = (\tau \rho)^{-1} (e_y^{k+1} - e_y^k), \quad (31)$$

我们有

$$\begin{aligned}
 & \frac{1}{\tau\rho} \left\langle e_y^{k+1}, e_y^k - e_y^{k+1} \right\rangle - (1 - \tau)\rho \|A_1 e_1^{k+1} + A_2 e_2^{k+1}\|^2 \\
 & + \rho \left\langle A_2(x_2^{k+1} - x_2^k), A_1 e_1^{k+1} + A_2 e_2^{k+1} \right\rangle \\
 & - \rho \left\langle A_2(x_2^{k+1} - x_2^k), A_2 e_2^{k+1} \right\rangle \geq 0.
 \end{aligned} \tag{32}$$

注意到不等式(32)和(30) 主要的差别在下面这一项上:

$$\rho \left\langle A_2(x_2^{k+1} - x_2^k), A_1 e_1^{k+1} + A_2 e_2^{k+1} \right\rangle.$$

接下来, 我们估计这一项的上界. 引入新符号

$$\nu^{k+1} := y^{k+1} + (1 - \tau)\rho(A_1 e_1^{k+1} + A_2 e_2^{k+1}),$$

$$M^{k+1} := (1 - \tau)\rho \left\langle A_2(x_2^{k+1} - x_2^k), A_1 e_1^k + A_2 e_2^k \right\rangle,$$

则 $-A_2^T \nu^{k+1} \in \partial f_2(x_2^{k+1})$, $-A_2^T \nu^k \in \partial f_2(x_2^k)$. 因 f_2 凸, 故

$$\left\langle -A_2^T(\nu^{k+1} - \nu^k), x_2^{k+1} - x_2^k \right\rangle \geq 0.$$

从而有

$$\begin{aligned}
& \rho \left\langle A_2(x_2^{k+1} - x_2^k), A_1 e_1^{k+1} + A_2 e_2^{k+1} \right\rangle \\
&= (1 - \tau) \rho \left\langle A_2(x_2^{k+1} - x_2^k), A_1 e_1^{k+1} + A_2 e_2^{k+1} \right\rangle \\
&\quad + \left\langle A_2(x_2^{k+1} - x_2^k), y^{k+1} - y^k \right\rangle \\
&= M^{k+1} + \left\langle \nu^{k+1} - \nu^k, A_2(x_2^{k+1} - x_2^k) \right\rangle \leq M^{k+1}.
\end{aligned}$$

因此, 不等式(32)可以放缩成

$$\begin{aligned}
& \frac{1}{\tau \rho} \left\langle e_y^{k+1}, e_y^k - e_y^{k+1} \right\rangle - (1 - \tau) \rho \|A_1 e_1^{k+1} + A_2 e_2^{k+1}\|^2 \\
&+ M^{k+1} - \rho \left\langle A_2(x_2^{k+1} - x_2^k), A_2 e_2^{k+1} \right\rangle \geq 0.
\end{aligned}$$

利用恒等式

$$\langle a, b \rangle = \frac{1}{2} (\|a\|^2 + \|b\|^2 - \|a - b\|^2) = \frac{1}{2} (\|a + b\|^2 - \|a\|^2 - \|b\|^2),$$

进一步得到

$$\begin{aligned} & \frac{1}{\tau\rho}(\|e_y^k\|^2 - \|e_y^{k+1}\|^2) - (2 - \tau)\rho\|A_1e_1^{k+1} + A_2e_2^{k+1}\|^2 \\ & + 2M^{k+1} - \rho\|A_2(x_2^{k+1} - x_2^k)\|^2 - \rho\|A_2e_2^{k+1}\|^2 + \rho\|A_2e_2^k\|^2 \geq 0. \end{aligned} \quad (33)$$

除了 M^{k+1} 中的项, (33)中的其他项均在不等式(30)中出现. 由于 M^{k+1} 的符号和 τ 的取法有关, 下面针对 τ 的两种取法进行讨论.

情形一 $\tau \in (0, 1]$: 此时 $(1 - \tau)\rho \geq 0$, 根据基本不等式, 可得

$$\begin{aligned} 2M^{k+1} &= 2(1 - \tau)\rho \left\langle A_2(x_2^{k+1} - x_2^k), A_1e_1^k + A_2e_2^k \right\rangle \\ &\leq (1 - \tau)\rho \left(\|A_2(x_2^{k+1} - x_2^k)\|^2 + \|A_1e_1^k + A_2e_2^k\|^2 \right). \end{aligned}$$

代入(33)得

$$\begin{aligned} & \frac{1}{\tau\rho}\|e_y^k\|^2 + \rho\|A_2e_2^k\|^2 + (1 - \tau)\rho\|A_1e_1^k + A_2e_2^k\|^2 \\ & - \left[\frac{1}{\tau\rho}\|e_y^{k+1}\|^2 + \rho\|A_2e_2^{k+1}\|^2 + (1 - \tau)\rho\|A_1e_1^{k+1} + A_2e_2^{k+1}\|^2 \right] \\ & \geq \rho\|A_1e_1^{k+1} + A_2e_2^{k+1}\|^2 + \tau\rho\|A_2(x_2^{k+1} - x_2^k)\|^2. \end{aligned} \quad (34)$$

情形二 $\tau > 1$: 此时 $(1 - \tau)\rho < 0$, 根据基本不等式

$$\begin{aligned} & -2 \left\langle A_2(x_2^{k+1} - x_2^k), A_1 e_1^k + A_2 e_2^k \right\rangle \\ & \leq \tau \|A_2(x_2^{k+1} - x_2^k)\|^2 + \frac{1}{\tau} \|A_1 e_1^k + A_2 e_2^k\|^2, \end{aligned}$$

可得

$$-2M^{k+1} \geq (1 - \tau)\rho \left(\tau \|A_2(x_2^{k+1} - x_2^k)\|^2 + \frac{1}{\tau} \|A_1 e_1^k + A_2 e_2^k\|^2 \right).$$

同样代入不等式(33)可以得到

$$\begin{aligned} & \frac{1}{\tau\rho} \|e_y^k\|^2 + \rho \|A_2 e_2^k\|^2 + \left(1 - \frac{1}{\tau}\right) \rho \|A_1 e_1^k + A_2 e_2^k\|^2 \\ & - \left[\frac{1}{\tau\rho} \|e_y^{k+1}\|^2 + \rho \|A_2 e_2^{k+1}\|^2 + \left(1 - \frac{1}{\tau}\right) \rho \|A_1 e_1^{k+1} + A_2 e_2^{k+1}\|^2 \right] \\ & \geq \left(1 + \frac{1}{\tau} - \tau\right) \rho \|A_1 e_1^{k+1} + A_2 e_2^{k+1}\|^2 \\ & + (1 + \tau - \tau^2) \rho \|A_2(x_2^{k+1} - x_2^k)\|^2. \end{aligned} \tag{35}$$

□

Theorem 2. 设必要假设成立且 A_1, A_2 列满秩. 如果 $\tau \in \left(0, \frac{1 + \sqrt{5}}{2}\right)$, 则序列 $\{(x_1^k, x_2^k, y^k)\}$ 收敛到问题(1)的一个KKT对, 也就是最优解.

Proof. 引理1表明 $\{\Phi_k\}$ 是有界序列, 故由 Φ_k 的定义(28)可知

$$\|e_y^k\|, \quad \|A_2 e_2^k\|, \quad \|A_1 e_1^k + A_2 e_2^k\|$$

均有界. 根据不等式

$$\|A_1 e_1^k\| \leq \|A_1 e_1^k + A_2 e_2^k\| + \|A_2 e_2^k\|,$$

可推出 $\{\|A_1 e_1^k\|\}$ 也是有界序列. 注意到 $A_1^T A_1 \succ 0, A_2^T A_2 \succ 0$, 因此 $\{(x_1^k, x_2^k, y^k)\}$ 是有界序列. 而且,

$$\sum_{k=0}^{\infty} \|A_1 e_1^k + A_2 e_2^k\|^2, \quad \sum_{k=0}^{\infty} \|A_2(x_2^{k+1} - x_2^k)\|^2$$

都是收敛的, 这表明

$$\|A_1 e_1^k + A_2 e_2^k\| = \|A_1 x_1^k + A_2 x_2^k - b\| \rightarrow 0, \quad \|A_2(x_2^{k+1} - x_2^k)\| \rightarrow 0. \quad (36)$$

由于 $\{(x_1^k, x_2^k, y^k)\}$ 是有界序列, 因此存在一个收敛子列, 设

$$(x_1^{k_j}, x_2^{k_j}, y^{k_j}) \rightarrow (x_1^\infty, x_2^\infty, y^\infty).$$

由(28)及(36)可得 $\{u^k\}$ 与 $\{v^k\}$ 相应的子列也收敛. 记

$$u^\infty \stackrel{\text{def}}{=} \lim_{j \rightarrow \infty} u^{k_j} = -A_1^\text{T} y^\infty, \quad v^\infty = \lim_{j \rightarrow \infty} v^{k_j} = -A_2^\text{T} y^\infty. \quad (37)$$

由(29)知, 对任意的 $k \geq 1$, 有 $u^k \in \partial f_1(x_1^k)$, $v^k \in \partial f_2(x_2^k)$. 由次梯度映射的图像是闭集可知

$$-A_1 y^\infty \in \partial f_1(x_1^\infty), \quad -A_2 y^\infty \in \partial f_2(x_2^\infty).$$

由(36)可知

$$\lim_{j \rightarrow \infty} \|A_1 x_1^{k_j} + A_2 x_2^{k_j} - b\| = \|A_1 x_1^\infty + A_2 x_2^\infty - b\| = 0.$$

这表明 $(x_1^\infty, x_2^\infty, y^\infty)$ 是问题(1)的一个KKT对. 因此上述分析中的 (x_1^*, x_2^*, y^*) 均可替换为 $(x_1^\infty, x_2^\infty, y^\infty)$.

注意到 $\{\Phi_k\}$ 是单调下降的, 且对子列 $\{\Phi_{k_j}\}$ 有

$$\begin{aligned} & \lim_{j \rightarrow \infty} \Phi_{k_j} \\ &= \lim_{j \rightarrow \infty} \left(\frac{1}{\tau\rho} \|e_y^{k_j}\|^2 + \rho \|A_2 e_2^{k_j}\|^2 + \max \left\{ 1 - \tau, 1 - \frac{1}{\tau} \right\} \rho \|A_1 e_1^{k_j} + A_2 e_2^{k_j}\|^2 \right) \\ &= 0. \end{aligned}$$

这说明

$$\|e_y^k\| \rightarrow 0, \quad \|A_2 e_2^k\| \rightarrow 0, \quad \|A_1 e_1^k + A_2 e_2^k\| \rightarrow 0.$$

进一步有

$$0 \leq \limsup_{k \rightarrow \infty} \|A_1 e_1^k\| \leq \lim_{k \rightarrow \infty} \left(\|A_2 e_2^k\| + \|A_1 e_1^k + A_2 e_2^k\| \right) = 0.$$

注意到 $A_1^T A_1 \succ 0, A_2^T A_2 \succ 0$, 故全序列 $\{(x_1^k, x_2^k, y^k)\}$ 收敛. □